

基于双通路融合网络的用户视频情感识别^{*}

刘玉杰^{1,2}, 董振阳^{1,2†}

(1. 中国石油大学(华东) 青岛软件学院、计算机科学与技术学院, 山东 青岛 266580; 2. 山东省智能油气工业软件重点实验室)

摘要: 用户视频的情感识别面临内容动态变化、画面主题多样及情感分布稀疏等挑战。针对此问题, 提出一种双通路融合网络 DPFNet。DPFNet 的核心是基于注意力机制的双通路编码结构, 主路径建模视觉嵌入的时序依赖关系, 辅助路径则引入情感辅助文本以重建和约束视觉特征以适应多样主题; 进一步, 通过双通路解码器并行解码两路特征, 捕获稀疏情感表达; 最后, 利用动态门控机制自适应融合双通路解码结果, 有效抑制与分类无关的通道干扰。在两个公开数据集上, DPFNet 分别取得了 60.2% 和 63.7% 的分类准确率。与当前主流模型相比, 所提方法在保持相当分类性能的前提下, 仅依赖视觉单模态输入即可实现更高效识别, 显著降低了模型复杂度与计算开销。

关键词: 用户视频; 视频情感识别; 视觉-语言模型; 辅助文本嵌入; 语义查询向量; 双路解码器; 动态门控融合
中图分类号: TP391

Emotion recognition in user-generated video based on dual-path fusion network

Liu Yujie^{1,2}, Dong Zhenyang^{1,2†}

(1. Qingdao Institute of Software, College of Computer Science and Technology, China University of Petroleum (East China), Qingdao Shandong 266580, China; 2. Shandong Key Laboratory of Intelligent Oil & Gas Industrial Software)

Abstract: Facing challenges from dynamic content, diverse themes, and sparse emotion distributions in user-generated videos, this paper developed a dual-path fusion network (DPFNet). The core of DPFNet was a dual-path encoding structure with attention mechanisms. The main path modeled temporal dependencies of visual embeddings, while an auxiliary path introduced emotional auxiliary text to reconstruct and constrain visual features for adaptation to diverse themes. A dual-path decoder then processed both paths in parallel to capture emotion-relevant visual content. Finally, a dynamic gating mechanism adaptively fused the decoded features to suppress task-irrelevant interference. Experiments on two public datasets show that DPFNet achieves classification accuracies of 60.2% and 63.7%, respectively. DPFNet demonstrates more efficient recognition using only visual modality input while maintaining comparable classification performance, significantly reducing model complexity and computational costs.

Key words: user-generated video; video emotion recognition; vision-language model; auxiliary text embedding; semantic querying vector; dual-path decoder; dynamic gating fusion

0 引言

视频情感识别是人机交互与人工智能领域的关键技术之一, 旨在通过计算模型自动识别与理解视频内容所传达的情感信息。视频承载着视觉画面(如面部表情和手势)、语音内容(如字幕与旁白)以及声学信息(如人声与环境音)等多模态情感数据, 为理解人类心理与社会动态提供了丰富的情感线索^[1]。大多数研究聚焦于受控录制条件下基于人体产生的信号对人类情感表达进行识别, 例如在 CMU-MOSI^[2]、IEMOCAP^[3]等结构一致性较高的专业视频数据集上评估多模态融合模型^[4-8]。尽管这些研

究推动了基于多模态情感融合的视频情感识别技术的发展, 但它们主要聚焦于说话者本身的情感表达, 而非揭示视频对观众产生的潜在情感影响。相比之下, 用户视频(User-generated video, UGV)中的情感识别更侧重于识别由多样化视频内容所激发的、潜意识的观看者情感。对此类视频进行准确的情感分析, 不仅有助于深入理解人类心理与社会行为机制, 也在个性化推荐、内容审核及人机交互等应用中具有重要价值。

与受控环境下录制的专业视频不同, 由于自由的拍摄手法和迥异的剪辑风格, 用户视频通常包含更加复杂和多变的视觉内容。这种复杂性给情感分析带来了三个主要挑战: 首先, 视

基金项目: 国家重点研发计划项目(2019YFF03018000); 国家自然科学基金项目(61379106); 山东省自然科学基金项目(ZR2013FM036, ZR2015FM011)

作者简介: 刘玉杰(1974-), 男, 辽宁沈阳人, 副教授, 硕导, 博士, 主要研究方向为计算机图形图像处理、多媒体数据分析; 董振阳(2001-), 男(通信作者), 浙江临海人, 硕士研究生, 主要研究方向为情感计算(s23070031@s.upc.edu.cn)。

频画面主题的多样性和情感表达的隐晦性使得低层视觉特征与高层情感语义之间存在显著的“情感鸿沟”^[9],即低层视觉模式与高层情感语义之间的领域差异;其次,用户视频的内容动态性强、场景切换频繁,导致视频前后内容之间的关联度低,这使得建模长程的时序依赖关系变得尤为困难;最后,用户视频中情感分布极为稀疏,即表达特定强烈情感的帧或片段在整体视频中占比较低,大量中性内容或无关噪声的存在使得模型难以精准捕捉到真正关键的情感线索。

目前,用户视频情感识别的研究主要致力于解决情感鸿沟问题。其中一部分研究尝试通过直接增强视觉特征的情感语义丰富度,来获取更贴近情感层次的特征表示。然而,该方法严重依赖计算资源,由于深度架构中反向传播的运算需求,往往带来高昂的计算成本^[10,11]。因此,越来越多的研究者转而致力于将固定的视觉表示映射到情感空间,通过设计可学习模块执行序列到序列映射来实现此目标,本文中称之为编码器范式。虽然该范式为应对情感鸿沟提供了实用途径,但相对简单的单层结构在先前工作中被证明效果有限。TE^[12]引入了多层堆叠的跨模态时序增强模块,展现了多层架构在视频情感识别中的有效性,但也因引入多个骨干网络牺牲了计算效率。此外,视频中的情感表达往往取决于少数情感峰值,标准的编码器模型连续处理所有时序元素,可能稀释情感峰值的影响并引入情感无关的噪声。更重要的是,现有方法大多依赖于音频和视觉的多模态融合,这不仅增加了数据采集与处理的复杂性,在现实应用中,音频模态的缺失或质量低下也可能导致模型性能的急剧下降。

为了应对上述挑战,本文提出了一种基于跨模态交互的双通路融合网络(dual-path fusion network, DPFNet)。该方法的核心思想是利用强大的预训练视觉-语言模型 CLIP^[13]所提供的语义对齐先验,通过预定义类别文本和辅助文本与视觉特征交互,引导模型从视觉模态中更精准地提取与情感相关的信息,借助多模态知识提升单模态模型的情感识别能力。具体而言,本文提出了一种双通路编码结构,其中主通路负责捕捉视觉序列的时序信息,以适应动态变化的视频内容;而辅助通路则通过情感辅助文本约束因画面主题多样而产生的复杂视觉嵌入。为了自适应地关注视觉嵌入中与情感高度相关的稀疏特征表示,采用基于注意力^[14]的解码器对双路信息分别解码。最后,通过一个动态门控融合模块聚合双路输出,从而在抑制噪声通道的同时突出关键情感信息。上述设计使 DPFNet 在本质上成为一种仅需视觉输入的高效模型。它通过视觉特征与少量固定的文本提示交互从而引入跨模态知识,无需依赖易缺失或低质量的音频信号,降低了对多模态数据的依赖,同时提高了识别效率。

1 相关工作

近年来,深度特征在视频情感识别中展现出显著提升。与手工特征相比,深度特征能提供更复杂、鲁棒的视频情感线索。VAANet^[15]提出新颖的端到端框架,使用空间、通道和时序注

意力处理多模态输入进行视频情感识别。Zhang 等^[10]利用无监督域自适应学习,结合情感图像数据集^[16]训练网络并获取与情感最相关的视觉特征。近期,CTEN^[17]通过挖掘关键片段之外的潜在上下文信息,创新性地提出时序擦除模块,擦除关键片段迫使模型从次相关片段中寻找情感线索。然而,这些方法依赖于 ImageNet^[18]和 Kinetics^[19]上预训练的 CNN 模型,其预训练任务主要聚焦于使用 ID 标签的前景主体识别,忽视了标签文本和背景场景中隐藏的语义信息。这一问题启发了对契合用户视频情感识别的预训练模型的探索。最近,视频理解任务(如动作识别)的最新进展探索了通过时序聚合模块将 CLIP 迁移到视频任务的方法,主流方法是直接通过时序处理模块将采样的图像特征映射到任务特定空间^[21,22]。这一成功实践主要得益于 CLIP 中常见动作描述与视觉语义能够在跨模态语义空间中轻易对齐。然而,由于情感鸿沟的存在,此类直接映射方法在视频情感分析中面临重大挑战。MM-VEMA^[11]首次迁移 CLIP 进行用户视频中的情感分析,但其依赖全参数微调策略,导致训练需要大量的显存开销。尽管如此,这项工作也充分展现了视觉-语言模型在用户视频情感识别问题上的潜力。为突破这一局限,本文探索了如何在冻结 CLIP 所有参数的情况下,在显著减少训练参数的同时,最大程度地提升模型在用户视频情感识别任务中的准确率。

为了将提取的特征进行一定程度的解耦处理,MPEM^[20]与本文所提出的双通路编码结构类似,使用多分支处理同一输入的不同变换特征。其通过构造多个并行的卷积分支,从同一视频输入中分别捕捉局部细微表情与全局肢体动作等不同空间尺度的特征,最终通过特征拼接或加权融合等方式,聚合形成多尺度视觉表示。CTEN 也有类似的多分支设计,其使用视觉输入和音频输入提取的特征进行跨模态的交叉注意力交互以及分别进行模态内的自注意力交互,从而增强模态间和模态内的时序联系。这些方法的出发点在于借助卷积或注意力模块搭建的通路促进信息交换,增强特征中有助于情感分析的信息量,却忽视了视频多模态数据中大量的噪声和复杂交互带来的信息冗余和干扰。为摆脱这一限制,本文的视角聚焦于如何减少无效信息,在主路径促进视觉输入动态交互的基础上,辅助路径以静态的、固定的辅助文本嵌入约束多样的视觉表达。因此,所提主辅双通路设计与此前方法提出的双路架构存在本质不同。

此外,现有方法大多采取序列到序列的特征交互方案,并将序列的平均信息作为分类依据。Li 等^[12]引入跨模态时间增强模块以同时交互多模态信息,通过在通道维度拼接多模态序列的平均向量表示送入分类器中。IFPN^[10]利用类激活图(class action mapping, CAM)判断每帧图片信息对情感分类的贡献度,并以加权平均法聚合视频级别的特征向量。VAANet 以端到端学习的方式训练一种对特征重要程度进行评估的价值网络,并将特征向量与评估的价值分数乘积之和作为分类依据。这些方法存在一定的局限性。在特征交互过程中,与最终情感分类最相关的、最具判别性的关键特征容易被大量相关性较低的特征

所稀释。尽管 IFPN 与 VAANet 试图通过权重分配来突出重要特征,但其对关键特征的选择机制仅作用在最终的序列输出上,并未真正参与到特征交互的过程中。因此,本文提出利用交叉注意力固有的筛选机制,使用一组固定长度的情感查询向量解码输入序列,在多层特征交互中实现对情感线索的关注。

2 模型描述

针对用户视频画面复杂多样、时序动态变化显著以及情感线索分布稀疏等挑战,本文设计了一种新颖的双通路融合网络,整体框架如图 1 所示。该网络包含两条并行路径:主路径通过自注意力机制建模原始视觉特征的时序依赖关系以适应动态变化的内容;辅助路径则通过交叉注意力机制引入固定的辅助文本嵌入来约束视觉特征在特定语义中表达,有效应对多样的画面主题。两条路径的输出通过共享参数的解码器进行并行解码,自适应地捕获稀疏的情感线索;通过门控融合机制动态地结合两条路径的信息,形成鲁棒的情感语义表征;最后,基于融合后的特征表示,通过计算相似度得分完成最终的情感分类。在公开数据集上的实验结果表明,所提方法有效提升了在用户视频场景下的情感分类性能。

2.1 视觉特征和文本特征提取

为了构建一个能够充分理解视频内容并关联语义情感的模型,分别从视觉与文本两个模态进行特征提取。模型采用 CLIP 模型作为特征提取器,以利用其在大规模跨模态预训练中获得丰富先验知识,为跨越情感鸿沟提供坚实的语义基础。




图 1 基于双通路融合网络的视频情感识别框架

Fig. 1 Video emotion recognition framework based on dual-path fusion network

2.1.1 视觉特征提取

给定一个输入视频,首先将其采样为一系列帧,构成图像帧序列 $F_v = [f_1, f_2, \dots, f_T]$, 其中 T 为序列长度。随后,将

每一帧图像 f_t 送入一个冻结参数的 CLIP 视觉编码器中,通过预训练的 CLIP 视觉编码器提取视觉特征。具体而言,对于每一帧,取其最终层输出的[cls]令牌作为该帧的帧级全局特征 $v_t \in \mathbb{R}^D$ 。最终,按照顺序嵌入可学习的位置编码向量^[23]后,得到整个视频的初始视觉特征序列 $V = \{v_1, v_2, \dots, v_T\} \in \mathbb{R}^{T \times D}$, 其中 D 为特征维度。在此过程中,CLIP 视觉编码器的参数保持冻结,此举不仅显著提升了训练效率,有效防止了过拟合,同时确保了所提取特征的泛化性与稳定性。

2.1.2 文本特征提取

为了将情感类别语义信息引入模型,本文构建了一组基于情感类别的语义查询向量。具体地,将数据集中所有的 N 个情感类别名称(例如, VideoEmotion-8^[24]中 8 个情感类别名称分别为“愤怒”、“期待”、“厌恶”、“恐惧”、“愉悦”、“悲伤”、“惊讶”、“信任”)逐个构造成文本提示(如“一个看起来令人感到[填充情感类别]的视频”),并送入冻结参数的 CLIP 文本编码器。与视觉特征提取不同,文本模态需要将排在文字令牌后的 [end]令牌作为全局特征,最终将所有类别文本对应的[end]令牌拼接得到查询向量 $E = [e_1; e_2; \dots; e_N] \in \mathbb{R}^{N \times D}$ 。同时必须指出,该查询向量包含了所有情感类别的信息,且对所有样本(包括训练集和测试集)保持一致,因此不存在对真值(ground truth)的泄露。此外,初始化一个可学习的全局上下文查询令牌 e_{cls} , 旨在聚合整个视频的全局上下文信息。最终,用于后

续并行解码的查询向量 $Q^{(0)}$ 由 e_{cls} 与查询向量 E 拼接而成,

可表示为 $Q^{(0)} = [e_{cls}; E] \in \mathbb{R}^{(1+N) \times D}$ 。该查询向量融合了全局表征与具体的类别语义,为解码器提供了明确的信息检索目标。如图 1 所示,查询向量 $Q^{(0)}$ 被分别送入主路径解码器和辅助路径解码器中与两路视觉嵌入进行跨模态交互,分别记作 $Q_m^{(0)}$ 和 $Q_n^{(0)}$ 以示区别。

同时,本文设计的辅助文本集合 $\mathcal{A}$ 共由九个短词汇构成,分别为“动物”、“场景”、“物体”、“自然”、“建筑”、“成人”、“儿童”、“男性”、“女性”。这些辅助文本是经过 GPT 归纳总结后,被认为能够囊括大部分用户视频内容的词汇概念集合。通过 CLIP 文本编码器对集合 $\mathcal{A}$ 中的词汇分别处理获取对应的辅助文本嵌入,该过程和构建语义查询向量类似,但不同点在于辅助文本嵌入不受数据集的影响,在实验中所用的两个数据集上保持一致。最终得到嵌入集合

$\mathbf{A} = [\mathbf{a}_1; \mathbf{a}_2; \dots; \mathbf{a}_9] \in \mathbb{R}^{9 \times D}$ 。如图 1 所示, 在交叉注意力模块中, 这些辅助文本嵌入根据与视觉嵌入 $\mathbf{V}$ 的相关性进行加权求和, 进而将多样的视觉嵌入约束在少量嵌入构成的语义空间中, 从而缓解视频内容多样导致识别困难的问题。

2.2 双通路编解码网络

2.2.1 多头注意力机制

所提编解码网络的设计核心是注意力机制, 其基本运算可表述为:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V} \quad (1)$$

在引入多头并行计算后可实例化为:

$$\text{MultiHeadAttention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}_{h=1}^H \left(\text{Attention}\left(\mathbf{Q}\mathbf{W}_q^{(h)}, \mathbf{K}\mathbf{W}_k^{(h)}, \mathbf{V}\mathbf{W}_v^{(h)}\right) \right) \quad (2)$$

其中 $\mathbf{Q}$ 为查询, $\mathbf{K}$ 为键, $\mathbf{V}$ 为值,

$\mathbf{W}_q^{(h)}, \mathbf{W}_k^{(h)}, \mathbf{W}_v^{(h)} \in \mathbb{R}^{D \times d_k}$ 为第 h 个注意力头的投影矩阵,

$d_k = D/H$, H 为注意力头总数。多头输出经拼接与线性投影后恢复至原始嵌入维度。多头计算使模型能并行关注不同语义子空间, 有效捕捉多样化情感线索。当特化为多头自注意力 (multi-head self-attention, MHSA) 时, 查询、键和值均来自同一输入序列 $\mathbf{X}$, 即 $\mathbf{Q} = \mathbf{K} = \mathbf{V} = \mathbf{X}$ 。因此, 多头自注意力表达如下:

$$\text{MHSA}(\mathbf{X}) = \text{MultiHeadAttention}(\mathbf{X}, \mathbf{X}, \mathbf{X}) \quad (3)$$

当特化为多头交叉注意力时, 查询来自输入序列 $\mathbf{X}$, 键和值来自另一序列 $\mathbf{Y}$, 即 $\mathbf{Q} = \mathbf{X}$, $\mathbf{K} = \mathbf{V} = \mathbf{Y}$ 。因此, 多头交叉注意力 (multi-head cross-attention, MHCA) 表达如下:

$$\text{MHCA}(\mathbf{X}) = \text{MultiHeadAttention}(\mathbf{X}, \mathbf{Y}, \mathbf{Y}) \quad (4)$$

2.2.2 双路注意力编码

由于视频的视觉信息是动态变化的, 仅对单帧级别的视觉嵌入进行独立处理难以捕捉诸如运动、场景转换等时序层面的信息。为此, 主编码路径旨在建模原始视觉嵌入之间的时序依赖关系, 通过自注意力机制捕捉视频帧间的时序关联:

$$\mathbf{V}_m = \text{MHSA}(\mathbf{V}) \quad (5)$$

其中, $\mathbf{V}_m$ 表示原始视觉嵌入 $\mathbf{V}$ 经过主路径中多头自注意力编码后得到的结果。另一方面, 在情感识别任务中, 同类别的样

本之间常存在显著的内容差异, 即便在同一视频中也会出现拍摄场景切换或用户多次剪辑, 容易造成画面内容与主题的剧烈变化。为应对这一问题, 本文设计了辅助编码路径, 通过引入少量固定的辅助文本嵌入, 并借助交叉注意力机制对视觉特征进行语义层面的重构, 从而将多样的视觉嵌入约束于辅助文本所定义的语义空间中:

$$\mathbf{V}_n = \text{MHCA}(\mathbf{V}, \mathbf{A}) \quad (6)$$

其中: $\mathbf{V}_n$ 表示以原始视觉嵌入 $\mathbf{V}$ 作为查询, 以辅助文本嵌入 $\mathbf{A}$ 作为键与值, 通过多头交叉注意力机制重构后得到的视觉表示。该机制使模型能够聚焦于与视觉内容高度相关的语义概念, 从而保障在语义空间中进行重构的合理性与有效性。

2.2.3 双路注意力解码

为承接并融合双路编码器输出的异构特征, 本文设计了一种基于语义查询向量的双路解码器。该解码器通过两条并行的路径, 分别与主路径特征 $\mathbf{V}_m$ 和辅助路径特征 $\mathbf{V}_n$ 进行深度交互,

最终通过动态门控融合机制生成鲁棒的情感语义表征。




图2 基于注意力机制的解码器设计

Fig. 2 Design of decoder based on attention mechanism

如图 2 所示, 解码器的核心是由 L 个堆叠的 Transformer 解码块 (transformer decoder block, TDB) 构成。每个解码块包含自注意力、交叉注意力和前馈网络三个核心组件, 并均辅以残差连接与层归一化来保障训练的稳定性。在第 l 个解码块

中, 语义查询向量 $\mathbf{Q} \in \mathbb{R}^{(N+1) \times D}$ 的更新过程如下:

$$\mathbf{Q}' = \text{LN}\left(\mathbf{Q}^{(l-1)} + \gamma_1 \odot \text{MHSA}^l(\mathbf{Q}^{(l-1)})\right) \quad (7)$$

$$\mathbf{Q}'' = \text{LN}\left(\mathbf{Q}' + \gamma_2 \odot \text{MHCA}^l(\mathbf{Q}', \mathbf{V}_x)\right) \quad (8)$$

$$\mathbf{Q}^{(l)} = \text{LN}\left(\mathbf{Q}'' + \gamma_3 \odot \text{FFN}^l(\mathbf{Q}'')\right) \quad (9)$$

其中: $\gamma_1, \gamma_2, \gamma_3 \in \mathbb{R}^D$ 为可学习的残差连接缩放系数, 初始阶段置零使公式 7~9 接近恒等映射, 在训练过程中逐渐学习到合适的缩放比例, 利于深层网络的训练; LN 表示层归一化计算 (layer norm); $\odot$ 表示逐元素进行乘积运算; $\mathbf{V}_x$ 代表输入该解码器的视觉嵌入 (即 $\mathbf{V}_m$ 或 $\mathbf{V}_n$)。自注意力层促进了语义查询向量间的内部交互, 以建立全局的语义上下文。随后的交叉注意力层则使语义查询能够有选择地从对应的视觉特征路径中捕获相关信息。此外在前馈网络 (feed forward network, FFN) 中, 采用高斯误差线性单元 (gaussian error linear units, GELU) 作为激活函数, 其表达式如下:

$$\text{GELU}(x) = x \cdot \Phi(x) \quad (10)$$

其中: $\Phi(x)$ 是标准高斯分布的累积分布函数。与标准的 ReLU 函数相比, GELU 通过其随输入值变化自适应调节的平滑门控特性, 提供了更平滑的非线性变换, 这有助于模型更细致地建模复杂的情感表达, 并在深层网络中缓解梯度消失问题。

在双路解码框架中, 两条路径独立且并行地处理视觉嵌入, 主路径对应 $\mathbf{V}_m$, 辅助路径对应 $\mathbf{V}_n$:

$$\begin{aligned} \mathbf{Q}_m^{(l)} &= \text{TDB}^l(\mathbf{Q}_m^{(l-1)}, \mathbf{V}_m) \\ \mathbf{Q}_n^{(l)} &= \text{TDB}^l(\mathbf{Q}_n^{(l-1)}, \mathbf{V}_n) \end{aligned} \quad (11)$$

值得注意的是, 两条路径中的 TDB 采用共享参数的设计。此举一方面能显著减少模型参数量, 防止过拟合; 另一方面, 它迫使同一处理模块学会同时理解原始视觉时序依赖和语义约束后的视觉特征, 从而学习到更具泛化性的情感感知模式。

经过 L 层解码块的处理后, 最终获得了两组富含不同视角信息的语义查询输出 $\mathbf{Q}_m^{(L)}$ 和 $\mathbf{Q}_n^{(L)}$ 。随后通过一个可学习的门

控权重对它们进行自适应融合, 形成足以支撑情感决策的表征。

2.3 双路动态门控融合

为自适应融合两条路径的信息, 本文设计了动态门控融合机制。首先对辅助路径输出进行投影并应用门控函数, 主路径

保留主要信息不做处理:

$$\begin{aligned} \mathbf{Q}_n &= \sigma\left(\mathbf{W}_g \left[\mathbf{Q}_n^{(L)}; \mathbf{Q}_m^{(L)}\right]\right) \odot \left(\mathbf{W}_p \mathbf{Q}_n^{(L)}\right) \\ \mathbf{Q}_m &= \mathbf{Q}_m^{(L)} \end{aligned} \quad (12)$$

其中: σ 为 GELU 函数, 相较于 Sigmoid 函数具有更灵活的调节范围, 可以同时实现特征增强和噪声抑制; $\mathbf{W}_g$ 和 $\mathbf{W}_p$ 为可学习参数。

考虑到两条路径特征范数的差异, 引入自适应缩放因子。对于每个位置的特征向量, 计算其对应的缩放因子:

$$\alpha_i = \min\left(1, \frac{\|\mathbf{Q}_m^i\|_2}{\|\mathbf{Q}_n^i\|_2}\right) \cdot w \quad (13)$$

其中 $\mathbf{Q}_m^i$ 和 $\mathbf{Q}_n^i$ 分别表示 $\mathbf{Q}_m$ 和 $\mathbf{Q}_n$ 在位置 i ($i \in \{0, 1, \dots, N\}$) 的特征向量, $\|\cdot\|_2$ 表示向量的 L2 范数, w 为可学习的缩放系数。令 $\boldsymbol{\alpha} = [\alpha_0, \alpha_1, \dots, \alpha_N]^\top$ 表示由所有位置缩放因子组成的向量, 其中 N 为空间位置总数 (同时也是类别数量)。最终融合结果为:

$$\mathbf{Q}_f = \mathbf{Q}_m + \boldsymbol{\alpha} \odot \mathbf{Q}_n \quad (14)$$

该门控机制允许模型根据具体的输入内容, 动态地权衡原始视觉时序特征与辅助文本约束特征对最终情感识别任务的相对重要性。这种设计使得模型能够在保持主路径稳定性的同时, 有效利用辅助路径提供的补充信息, 抑制无关通道表达, 从而缓解深层网络的过拟合问题, 提升模型对复杂情感模式的建模能力。

2.4 情感预测与损失函数

从融合后的查询向量 $\mathbf{Q}_f = [\mathbf{e}_{cls}; \mathbf{E}] \in \mathbb{R}^{(1+N) \times D}$ 分离出全局查询令牌 $\mathbf{e}_{cls}$ 和情感类别令牌集合 $\mathbf{E}$, 分别进行 L2 范数归一化后计算相似度得分 $\mathbf{y} \in \mathbb{R}^N$:

$$\mathbf{y} = \frac{\mathbf{e}_{cls} \mathbf{E}^\top}{\tau} \quad (15)$$

其中: τ 为温度参数。为了将相似度得分 $\mathbf{y}$ 转换为情感类别的概率分布, 使用 Softmax 函数进行处理:

$$p_i = \frac{\exp(y_i)}{\sum_{j=1}^N \exp(y_j)} \quad (16)$$

其中: $\mathbf{p} \in \mathbb{R}^N$ 是一个概率向量, 其每个元素 p_i 表示查询

令牌 e_{cls} 属于第 i 个情感类别的预测概率。在训练过程中，为了优化模型参数，采用交叉熵进行损失函数计算。

3 实验

3.1 数据集

与先前研究相同，本文在 VideoEmotion-8^[24]数据集和 Ekman-6^[25]数据集上评估所提方法。VideoEmotion-8 数据集包含从视频网站（YouTube 和 Flickr）采集的 1,101 个视频，标注有八种情感类别，平均时长 107 秒。为与现有工作公平比较，以开源数据集规定的划分方式进行十次 2:1 训练-测试划分的实验，取所有实验的平均准确率。类似地，Ekman-6 数据集包含 1,637 个来自 YouTube 和 Flickr 的视频，标注有六种基本情感，平均时长 112 秒。两个数据集包含的具体情感类别在表 1 中展示。本文遵循先前研究使用的 1:1 训练-测试划分配置，并采用不同随机种子进行实验取平均准确率作为对比指标。

表 1 数据集信息

Table 1 Dataset information		
数据集名称	样本数量	类别标签
VideoEmotion-8 (VE-8)	1101	“愤怒”、“期待”、“厌恶”、“恐惧”、“愉悦”、
		“悲伤”、“惊讶”、“信任”
Ekman-6 (EK-6)	1637	“愤怒”、“厌恶”、“恐惧”、“愉悦”、“悲伤”、
		“惊讶”

3.2 实现细节

每个视频被划分为 16 个连续的非重叠时序片段。在训练阶段，从每个片段中随机采样一帧；评估阶段则采用每个片段的中心帧采样以确保可复现性。空间归一化方面，每帧图像被调整为 224×224 分辨率，推理期间通过中心裁剪保持宽高比。为缓解训练过拟合，本文采取简单的数据增强策略，通过随机缩放裁剪（尺度参数采样自区间[0.64, 1]，宽高比限制在区间[3/4, 4/3]）进行图像变换。需要注意的是，同一视频序列中的所有图像采用相同的空间裁剪坐标以保持数据增强在时间上的一致性。DPFNet 采用 CLIP B/32 作为骨干网络提取帧级别的视觉特征，其中的多头注意力模块均采用 512 维的嵌入维度和 8 个注意力头设置。此外将温度超参数 τ 设为 0.01，解码块 L 的数量设为 4。

优化方面，本文采用 Adam 优化器，使用 $2e-4$ 学习率训练 50 个周期，批次大小为 16。所有实验均遵循情感识别标准评估实践，采用单标签情感分类方法，性能通过 Top-1 准确率（%）量化。

3.3 与最先进方法的对比

3.3.1 对比方法

为了验证所提模型的有效性，与现有模型进行比较：

a) ITE^[25]：通过引入外部情感图像数据集的知识，设计图像迁移编码算法，将帧级别特征聚合为具有情感语义的视频级别表示。

b) VAANet^[15]：首次提出使用 3D 卷积神经网络捕获视频中的时序特征、2D 卷积神经网络捕获音频频谱特征，是用户视频情感识别领域内第一个端到端学习的深度网络。

c) TAM^[26]：提出时间感知多模态方法，设计跨时段多模态融合模块以充分捕捉模态内与模态间的时间依赖关系，并创新性地利用时间同步评论作为辅助监督，通过两个自监督预训练任务从大规模无标注数据中学习视频片段的情感时序模式，在多个基准数据集上取得领先性能。

d) CTEN^[17]：在 VAANet 基础上创新性地提出时序擦除模块，通过擦除关键片段迫使模型从非关键片段中寻找情感线索，挖掘关键片段之外的潜在上下文信息，

e) IFPN^[10]：与 ITE 相似，引入外部情感图像数据集并获取与情感最相关的视觉特征。不同点在于 IFPN 创新性地采用生成对抗网络，通过混淆情感图像数据和视频帧图像数据实现无监督域自适应学习。

f) LRCANet^[27]：为建模视频中的长程上下文相关性，提出时空相关性感知块，通过卷积层与图像间交叉注意力分别学习局部及长程时空关联。

g) MPEM^[20]：针对视频情感识别中多尺度时空特征的提取与融合问题，通过不同扩张率的卷积核分层捕捉从面部微表情到肢体动作的跨尺度特征，并结合动态特征适配器进行自适应的多源特征融合。

h) MM-VEMA^[11]：首次提出将 CLIP 模型应用于用户视频情感识别，以全参数微调的方式在多个基准数据集上取得领先性能。

i) TE^[12]：将离散采样的帧图像序列视为除连续视频和音频之外的第三种模态输入，并设计跨模态时间增强模块以同时交互多模态信息，实现了先进性能。

3.3.2 分类识别能力

本文在表 2 中将 DPFNet 与其它先进方法在 VideoEmotion-8 和 Ekman-6 数据集上进行了比较。表格中“模态”一列的“V”代表接受视觉模态输入，“A”代表接受音频模态的输入；“扩充数据”一项被勾选的方法代表着其使用了外部的数据集辅助训练或者决策。与先前的用户视频基准相比，所提框架的优越性尤为明显。所提 DPFNet 分别在这两个数据集上取得了 60.2%和 63.7%的 Top-1 准确率，该分数超越了除 TE 模型外其他的所有方法。值得注意的是，虽然 TE 在用户视频基准上取得了有竞争力的结果，但所提架构在 VE-8 上实现了+0.4%的性能提升，在 EK-6 数据集上也表现出与 TE 相当的性能。同时 TE 接受三模态输入，分别使用了三种骨干网络形成了参数量庞大的总体网络，这表明 DPFNet 使用了更少的模态输入以及更少的模型参数，展现了 DPFNet 在用户视频情感理解方面的卓越效率。

表 2 与最先进方法的对比实验

Table 2 Comparison with state-of-the-art approaches				
模型	发表刊物	模态	扩充数据	Top-1 准确率（%）

				VE-8	EK-6
ITE	TAC'16	V+A	✓	52.6	55.6
VAANet	AAAI'20	V+A		54.5	55.3
TAM	ACM MM'22	V+A	✓	57.5	61.0
CTEN	CVPR'23	V+A		57.3	58.2
IFPN	TMM'23	V	✓	57.6	60.4
LRCANet	IET IP'24	V+A		57.4	59.8
MPEM	Electronics'25	V+A		57.6	61.3
MM-VEMA	PRCV'23	V		59.4	62.8
TE	ACM MM'24	V+A		<u>59.8</u>	64.8
DPFNet	本文方法	V		60.2	<u>63.7</u>

3.3.3 模型效率分析

首先对表 3 中的度量单位和设置进行必要的解释。表格中“可训练参数量”和“显存使用量”的度量单位分别为 MB 和 GB;“输入帧数”一栏统一形式为 $S \times F$ ，实际意义为将视频切分为不重叠的 S 个片段，每个片段采样 F 帧。如表 3 所示，尽管更简单的编码器方法 VAANet 能够与 DPFNet 在模型效率方面相当,可训练参数量和显存使用量均仅高于所提 DPFNet，但该方法在识别性能上远落后于现阶段最先进方法的性能。在识别表现较优的方法中，DPFNet 表现出较低的计算需求。目前识别准确率最高的 TE 方法的可训练参数量是所提 DPFNet 的十倍，其采用多层跨模态时序增强模块经过训练以增强模态间相关性,但需要比其他任何方法都多的计算资源。相比之下，DPFNet 保持在较少可训练参数的同时实现了最先进的性能，在计算需求和模型效果之间建立了最佳平衡。

MM-VEMA 在处理相同数量的输入帧时，需要大约 3 倍于 DPFNet 的显存容量。相比之下，同样是单模态方法的 DPFNet 是模型效率更高的架构，因为其采用冻结的预训练主干网络，同时仅训练部分模块。这种模型效率和识别准确率的优势使 DPFNet 有望成为在线视频情感理解等现实应用的理想选择。

表 3 模型效率对比

Table 3 Model efficiency comparison				
模型	可训练参数量	模态	输入帧数	显存使用量
VAANet	<u>48.2</u>	V+A	8×16	<u>6.9</u>
CTEN	202.9	V+A	8×16	12.5
MM-VEMA	577.1	V	16×1	16.4
TE	386.3	V+A	8×16	17.9
DPFNet	38.7	V	16×1	5.4

3.4 消融实验与分析

为验证本文提出的双路融合网络中各组件的有效性，本文在 VideoEmotion-8 数据集上进行了系统的消融实验。所有实验均采用相同的训练策略和超参数设置，以确保比较的公平性。

3.4.1 关键组件有效性分析

表 4 展示了双路融合网络中关键组件的消融结果，表格中的短划线表示仅使用单路特征的情况下相应设置无讨论意义。首先，仅使用主路径时，模型在 VideoEmotion-8 数据集上的平

均准确率为 57.3%，表明基于自注意力的时序建模能够有效捕捉视频帧间的情感依赖关系。单独使用辅助路径时，由于缺乏原始视觉信息和时序信息共同导致的情感线索丢失，性能略微下降至 55.8%。

当同时使用主路径和辅助特征经过共享参数的双路解码器解码但未引入门控融合时（简单相加），性能显著提升至 58.8%，验证了主路径和辅助路径特征具有互补的特性，同时也表明辅助路径编码可通过约束视觉语义表达从而提升模型的识别效果。最后，引入本文提出的门控融合机制后，模型达到最佳性能（60.2%），验证了自适应特征融合能够更有效地从辅助路径中提取和主路径互补的信息。

关于解码器参数共享对识别效果的实际影响，在表格中最后一行反映了主路径和辅助路径分别采用两个独立的解码器时模型的表现。在增加了额外的模型参数的同时，模型的性能略微下降,反映出模型无法有效利用两条路径中共通的解码规则，验证了共享参数设置的合理性。

表 4 关键组件消融实验

Table 4 Ablation study on main components				
主路径	辅助路径	门控融合	解码器参数共享	准确率
✓	×	-	-	57.3
×	✓	-	-	55.8
✓	✓	×	✓	58.8
✓	✓	✓	✓	60.2
✓	✓	✓	×	59.4

3.4.2 时序编码模块分析

表 5 比较了不同时序编码方法在 DPFNet 中的表现。实验方式为，将主路径的原时序编码方法替换为时序建模任务中常见的几种方法。实验结果表明，基于 Attention 的原方法分别在 VideoEmotion-8 和 Ekman-6 数据集上取得 60.2%与 63.7%的最佳性能。传统的 GRU 和 BiLSTM 方法由于长程依赖建模能力的限制,性能相对较低。与结果相对较优的 GRU 相比，Attention 在两个数据集上的准确率分别提升 1.6 与 1.1 个百分点。与不采用任何时序编码方法（即恒等映射 Identity 层）相比，准确率分别提升 3.0 和 3.8 个百分点，验证了所提基于 Attention 的时序编码模块的有效性。

表 5 时序编码方法有效性分析

Table 5 Analysis of the effectiveness of temporal encoding methods		
时序编码方式	VideoEmotion-8	Ekman-6
Identity	57.2	59.9
BiLSTM	58.2	62.1
GRU	58.6	62.6
Attention	60.2	63.7

3.4.3 辅助文本集合规模的敏感性分析

为探究辅助文本集合规模对模型性能的影响，本文设计了规模分别为 5、9、15 的三组词汇进行对比实验。其中，规模为 9 的词汇集合为原文设定，作为基准集合，覆盖“人物”、“场

景”、“物体”等高层语义类别；规模为5的词汇集合为基准集合的子集，聚焦于非人物类别，仅保留“动物”、“场景”、“物体”、“自然”、“建筑”这五个词汇；规模为15的词汇集合则在基准集合的基础上扩展了“光线”、“食物”、“植物”、“景观”、“废弃物”、“艺术品”六个词汇。在 VideoEmotion-8 和 Ekman-6 数据集上的实验结果如表 6 所示。实验表明，规模为9时模型取得最佳性能。规模减小会导致语义覆盖面存在不足，规模增大则可能引入冗余信息，反而轻微降低识别效果。该结果说明，当前所选9个词汇在表达丰富性与模型泛化能力之间达到了较好平衡，同时间接验证了基准词汇集合设置的合理性。

表 6 辅助文本集合规模的敏感性分析

Table 6 Sensitivity analysis of auxiliary text set size		
词汇规模	VideoEmotion-8	Ekman-6
5	58.1	62.2
9	60.2	63.7
15	59.9	63.5

3.4.4 CLIP 参数微调策略分析

大规模视觉-语言预训练模型的参数更新策略是影响下游任务性能的关键。为探究不同策略对 DPFNet 的影响，并验证完全冻结策略的合理性，本文设计了一组针对不同参数微调策略的消融实验。以原文设定的“完全冻结 CLIP 视觉与文本编码器”作为基线，分别对视觉编码器和文本编码器进行不同程度的解冻微调。具体策略包括：微调最后一层、微调最后两层（第 11-12 层）、微调最后四层（第 9-12 层）以及微调全部参数。不同微调策略在 VideoEmotion-8 数据集上的性能对比如表 7 所示。实验结果表明，完全冻结 CLIP 编码器参数是效果最好的设置，任何程度的微调都会导致性能下降，且解冻层数越多，性能衰退越显著。对视觉编码器进行微调造成的性能下降极为严重，在完全微调情况下将导致准确率下降 35.0%。经过分析其原因主要在于训练数据规模有限，微调参数数量巨大的 CLIP 模型极易引发过拟合。因此，保持 CLIP 参数冻结，能够最有效地利用其先验知识，确保模型在情感识别任务上的鲁棒性能。

表 7 CLIP 参数微调策略分析

Table 7 Analysis of CLIP parameter fine-tuning strategy		
微调目标	策略	准确率
视觉编码器	全部冻结	60.2
	微调第 12 层	55.2
	微调第 11-12 层	48.9
	微调第 9-12 层	33.1
	微调全部参数	25.2
文本编码器	微调第 12 层	59.8
	微调第 11-12 层	57.7
	微调第 9-12 层	53.6
	微调全部参数	44.2

3.5 超参数实验和分析

3.5.1 解码块数量

解码块数量 L 决定了模型处理视觉与文本特征交互并进行推理的容量。本文在 $L \in \{2, 4, 6, 8\}$ 的范围内进行实验。如图 3 所示，当 $L = 4$ 时，模型在 VideoEmotion-8 数据集上达到 60.2% 的最高准确率。当 $L = 2$ 时，模型分类能力受到明显限制；当 L 增加至 6 乃至 8 时，模型表现出性能的轻微连续下降，这可能是因为在有限数据下，更深的网络引发了轻微的过拟合和优化困难。因此，将 L 设置为 4 是模型表现与参数量之间的一个理想平衡点。




图 3 解码块数量对模型分类性能的影响

Fig. 3 The impact of decoding block quantity on model classification performance

3.5.2 温度系数

温度系数 τ 在公式(15)中用于缩放相似度得分，控制预测分布的平滑度。在 CLIP 的设置中 τ 是一个可学习的参数，其值接近 0.01。因此，在下游任务中通常使用该值作为温度系数的固定值。本文在 $\tau \in \{0.001, 0.01, 0.1\}$ 范围内进行测试。

如图 4 所示，当 $\tau = 0.01$ 时性能最佳；当 $\tau = 0.001$ 时，分布过于尖锐，较小的 τ 会造成训练的不稳定；当 $\tau = 0.1$ 时，分布过于平滑，削弱了模型对难样本的判别能力。




图 4 温度系数对模型分类性能的影响

Fig. 4 The impact of temperature coefficient on model classification

performance

3.6 案例分析

3.6.1 多组案例的定量分析

本文筛选了三组内容相似的来自 VideoEmotion-8 数据集上各类别的视频样本进行多组案例分析。其中一组包括十个拍摄内容为记录孩童生活的视频，第二组为七个内容为动物的视频，第三组为十个城市或自然景观的视频，具体的类别分布见表 8。

表 8 多组案例的定量分析

Table 8 Quantitative analysis of multiple cases

组序	内容	样本量	样本分布
1	孩童	10	愤怒 2 愉悦 2 悲伤 2 期待 2 惊讶 2
2	动物	7	恐惧 2 厌恶 2 期待 2 信任 1
3	景观	10	愉悦 4 悲伤 3 期待 1 信任 2

在组 1 中,所提方法正确预测的样本数量为 5,作为对比,复现的 CTEN 在该组中正确预测的数量为 6,MM-VEMA 正确预测的数量为 4。DPFNet 和 MM-VEMA 作为整体预测准确率更高的方法,在该组案例中表现不佳的共同原因在于它们同为单视觉模态的方法,容易被相似内容的不同情感混淆。而在第二组和第三组中,DPFNet 分别正确预测了 5 和 8 个样例,MM-VEMA 正确预测了 5 和 7 个样例,而 CTEN 仅正确预测了 3 和 5 个样例,这反映了在 Kinetics 动作数据集上预训练的 CNN 模型的局限性,它使得模型无法解读出复杂多样的画面内容中集中体现情感线索的信息。

3.6.2 案例可视化分析

为探究辅助文本如何影响模型分类,本文基于对视频帧的定位分析结合原视频画面的可视化来展示辅助文本对决策的影响。在 DPFNet 中,模型在解码器部分借助语义查询向量和交叉注意力关注视觉序列中重要的部分并抽取可用信息,而查询向量是最终决策的依据。因此,借助交叉注意力矩阵,可以分析得出序列中的哪些向量是被查询向量重点关注的。这些向量对应的注意力分数的反映了向量的受关注程度,因此将其命名为受关注分数。本文利用解码器最后一层的交叉注意力矩阵展开分析,因为其最接近决策层。同时,将多头注意力沿注意力头维度平均池化以得到多头平均注意力矩阵,获取更能够代表查询向量关注度的平均信息。由于双路解码器的设置,该注意力矩阵在主路径分支和辅助路径分支均会存在,分别反映主路径和辅助路径中哪些向量被查询向量关注。为方便表示,主路径中各向量的受关注分数统一记为 s_1 ,辅助路径则记为 s_2 。

图 5 展示了一个类别为“信任”的视频样本所包含的长度为 16 的向量序列对应的图像可视化和受关注分数。在此案例中,主路径最受关注的四个视觉序列向量序号分别为 2、5、8、15,最不受关注的序号分别为 1、12、13、14;辅助路径最受关注的四个序号分别为 3、5、6、7,最不受关注的序号分别为 1、10、12、15。可以看出主路径更关注要素构成简单且情感倾向

明确的图像,例如第 2 和第 8 张以“狗”为主体的画面。“狗”在语义与“忠诚”、“伙伴”等词有潜在的关联,这可能是这些序列受关注的原因。辅助路径由辅助文本嵌入完全重构,因此不可能包含和“狗”一般具体的信息,但辅助路径仍然关注到了第 3 和第 7 幅图像,这是辅助文本中“动物”一词对视觉输入重塑作用的体现。此外,辅助文本对视觉表达的约束作用在不受关注的向量上体现的更为明显。可以观察到,第 1 和第 10 幅图像都是较为空旷的背景,在此案例中无法提供有效信息;第 15 幅图像是与内容无关的字幕。这表明辅助文本降低了未被其定义的信息的关注度。主路径虽然同样降低了对空旷背景内容的关注,但忽视了类似于第 6、第 13 幅图像人与狗关系密切、同样能体现“信任”的画面。这些结论很好地揭示了主路径和辅助路径在决策过程中的倾向,同时验证了辅助文本对决策结果的正向影响。




图 5 视频样本可视化分析

Fig. 5 Visual analysis of video sample

4 结束语

本文针对用户视频情感识别任务,提出了一种基于跨模态交互的双路融合网络(DPFNet)。由于情感鸿沟的存在,从视觉内容到情感表达之间的语义关联是视频情感识别的关键。模型采用冻结参数的 CLIP 骨干网络提取鲁棒的视觉与文本特征,利用其强大的跨模态对齐能力为情感分析提供语义基础。为了发挥视觉-语言模型在情感识别中的优势,模型设计了双通路编码结构,主通路通过自注意力机制建模视觉序列的时序依赖,辅助通路则引入情感辅助文本的语义知识来约束视觉特征表达。实验结果表明,双通路设计在一定程度上形成互补,有效提升了模型的准确性和鲁棒性。为克服视频中情感分布稀疏的问题,采用参数共享的双通路 Transformer 解码器,通过交叉注意力机制并行挖掘两路特征中的显著情感信息。最后,通过门控融合

模块自适应聚合双路输出,有效抑制无关通道并突出关键情感内容。在两个公开数据集上的实验结果表明,所提模型有效提升了情感识别的准确率,同时降低了计算开销,提高了模型效率。

在未来工作中,辅助文本的设计是值得深入探索的方向,以层次划分的辅助文本集或者结合检索增强技术可以提供更加合理的文本内容。此外后续研究将考虑使用蒸馏的方式在小模型上进一步提升模型效率,并拓展到在线视频情感识别的新研究领域。

5 参考文献

- [1] 陶建华, 范存航, 连政, 等. 多模态情感识别与理解发展现状及趋势 [J]. 中国图象图形学报, 2024, 29(06): 1607-1627. (Tao Jianhua, Fan Cunhang, Lian Zheng, et al. Development of multimodal sentiment recognition and understanding [J]. Journal of Image and Graphics, 2024, 29(06): 1607-1627.)
- [2] Zadeh A, Zellers R, Pincus E, et al. Multimodal sentiment intensity analysis in videos: facial gestures and verbal messages [J]. IEEE Intelligent Systems, 2016, 31 (6): 82-88.
- [3] Busso C, Bulut M, Lee C C, et al. IEMOCAP: interactive emotional dyadic motion capture database [J]. Language resources and evaluation, 2008, 42(4): 335-359.
- [4] Zadeh A, Chen M, Poria S, et al. Tensor fusion network for multimodal sentiment analysis [C]// Proc of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 1103-1114.
- [5] Rahman W, Hasan M K, Lee S, et al. Integrating multimodal information in large pretrained transformers [C]// Proc of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 2359-2369.
- [6] Mai Sijie, Zeng Ying, Zheng Shuangjia, et al. Hybrid contrastive learning of tri-modal representation for multimodal sentiment analysis [J]. IEEE Trans on Affective Computing, 2022, 14(3): 2276-2289.
- [7] 缪裕青, 杨爽, 刘同来, 等. 基于跨模态门控机制和改进融合方法的多模态情感分析 [J]. 计算机应用研究, 2023, 40 (07): 2025-2030+2038. (Miao Yuqing, Yang Shuang, Liu Tonglai, et al. Multimodal sentiment analysis based on cross-modal gating mechanism and improved fusion method [J]. Application Research of Computers, 2023, 40 (07): 2025-2030+2038.)
- [8] 冯广, 刘馨婷, 林忆宝, 等. 基于统一对齐与多阶段融合机制的多模态情感分析模型 [J/OL]. 计算机应用研究, 1-12 (2025-10-28)[2025-12-02]. <https://doi.org/10.19734/j.issn.1001-3695.2025.06.0214>.
- (Feng Guang, Liu Xinting, Lin Yibao, et al. Multimodal sentiment analysis model based on unified alignment and multi-stage fusion [J/OL]. Application Research of Computers, 1-12 (2025-10-28)[2025-12-02]. <https://doi.org/10.19734/j.issn.1001-3695.2025.06.0214>.)
- [9] Xu Liwen, Wang Zhengtao, Wu Bin, et al. MDAN: multi-level dependent attention network for visual emotion analysis [C]// Proc of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2022: 9479-9488.
- [10] Zhang Haimin, Xu Min. Recognition of emotions in user-generated videos through frame-level adaptation and emotion intensity learning [J]. IEEE Transactions on Multimedia, 2023, 25: 881-891.
- [11] Pu Hao, Sun Yuchong, Song Ruihua, et al. Going beyond closed sets: a multimodal perspective for video emotion analysis [C]// Chinese Conference on Pattern Recognition and Computer Vision. Singapore: Springer Nature Singapore, 2023: 233-244.
- [12] Li Xin, Wang Shangfei, Huang Xuandong. Temporal enhancement for video affective content analysis [C]// Proc of the 32nd ACM International Conference on Multimedia. New York: ACM Press, 2024: 642-650.
- [13] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision [C]// International Conference on Machine Learning. 2021: 8748-8763.
- [14] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J]. Advances in Neural Information Processing Systems, 2017, 30.
- [15] Zhao Sicheng, Ma Yunsheng, Gu Yang, et al. An end-to-end visual-audio attention network for emotion recognition in user-generated videos [C]// Proc of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2020, 34(01): 303-311.
- [16] You Quanzeng, Luo Jiebo, Jin Hailin, et al. Building a large scale dataset for image emotion recognition: the fine print and the benchmark [C]// Proc of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2016, 30(1).
- [17] Zhang Zhicheng, Wang Lijuan, Yang Jufeng. Weakly supervised video emotion detection and prediction via cross-modal temporal erasing network [C]// Proc of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2023: 18888-18897.
- [18] Deng Jia, Dong Wei, Socher R, et al. Imagenet: a large-scale

- hierarchical image database [C]// 2009 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2009: 248-255.
- [19] Carreira J, Zisserman A. Quo vadis, action recognition? a new model and the kinetics dataset [C]// Proc of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2017: 6299-6308.
- [20] Zhang Lianqi, Sun Yuan, Guan Jiansheng, et al. Multi-scale parallel enhancement module with cross-hierarchy interaction for video emotion recognition [J]. Electronics, 2025, 14(9): 1886.
- [21] Kahatapitiya K, Arnab A, Nagrani A, et al. Victr: video-conditioned text representations for activity recognition [C]// Proc of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2024: 18547-18558.
- [22] Yu Yating, Cao Congqi, Zhang Yueran, et al. Building a multi-modal spatiotemporal expert for zero-shot action recognition with clip [C]// Proc of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2025, 39(9): 9689-9697.
- [23] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale [EB/OL]. (2020-10-22)[2025-12-22]. <https://arxiv.org/abs/2010.11929>.
- [24] Jiang Y G, Xu Baohan, Xue Xiangyang. Predicting emotions in user-generated videos [C]// Proc of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2014, 28(1).
- [25] Xu Baohan, Fu Yanwei, Jiang Y G, et al. Heterogeneous knowledge transfer in video emotion recognition, attribution and summarization [J]. IEEE Trans on Affective Computing, 2016, 9(2): 255-270.
- [26] Pan Jicai, Wang Shangfei, Fang Lin. Representation learning through multimodal attention and time-sync comments for affective video content analysis [C]// Proc of the 30th ACM International Conference on Multimedia. New York: ACM Press, 2022: 42-50.
- [27] Yi Yun, Zhou Jin, Wang Hanli, et al. Emotion recognition in user-generated videos with long-range correlation-aware network [J]. IET Image Processing, 2024, 18(12): 3288-3301.