

中图分类号: TE391

单位代码: 10425

学 号: S23070031



中國石油大學

硕士学位论文

Master Degree Thesis of China University of Petroleum

基于多模态知识的视频情感识别研究

Research on Video Emotion Recognition Based on
Multimodal Knowledge

学科专业: 计算机科学与技术

研究方向: 图形图像处理与可视化

作者姓名: 董振阳

指导教师: 刘玉杰 副教授

二〇二六年五月

Research on Video Emotion Recognition Based on Multimodal Knowledge

A Thesis Submitted for the Degree of Master

Candidate: Zhenyang Dong

Supervisor: Yujie Liu

College of Computer Science and Technology
China University of Petroleum (East China)

学位论文答辩委员会

答辩时间	2026 年 5 月 17 日		
答辩地点	西廊 102		
答辩委员会组成			
组成	姓名	职称	工作单位
主席	于彦伟	教授	中国海洋大学
委员	张俊三	教授	中国石油大学（华东）
	张培颖	教授	中国石油大学（华东）
	王雪瑞	副教授	中国石油大学（华东）
	蒋狄琮	副教授	中国石油大学（华东）

关于学位论文的独创性声明

本人郑重声明：所呈交的论文是本人在指导教师指导下独立进行研究工作所取得的成果，论文中有关资料和数据是实事求是的。尽我所知，除文中已经加以标注和致谢外，本论文不包含其他人已经发表或撰写的研究成果，也不包含本人或他人为获得中国石油大学（华东）或其它教育机构的学位或学历证书而使用过的材料。与我一同工作的同志对研究所做的任何贡献均已在论文中作出了明确的说明。

若有不实之处，本人愿意承担相关法律责任。

学位论文作者签名：董振阳

日期： 2026 年 5 月 16 日

学位论文使用授权书

本学位论文作者完全了解中国石油大学（华东）有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交学位论文的复印件和电子版，允许本学位论文被查阅和借阅。本人授权中国石油大学（华东）可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用复印、缩印、扫描或其它手段保存和汇编本学位论文。（保密的学位论文在解密后适用本授权书）

学位论文作者签名：董振阳

日期： 2026 年 5 月 16 日

指导教师签名：刘玉东

日期： 2026 年 5 月 16 日

摘 要

视频情感识别是指从视频包含的多模态信息中分析、识别视频内容所传达的情感，在教育、安全和医疗等众多领域具有应用需求。当前，大多数视频情感识别研究聚焦于受控录制条件下基于人体产生的多模态信号进行情感识别。然而，此类方法在面对拍摄于复杂场景的视频时，其识别效果与泛化能力仍显不足，难以实现有效应用。自由的拍摄手法、迥异的剪辑风格和多样的视频内容，这些固有的特点使得复杂场景中的视频情感识别面临视频内容动态变化、画面主题多样以及情感分布稀疏等严峻挑战。除此之外，缺少大规模情感标注视频数据集进一步限制了相关模型的训练与性能提升，使得现有方法难以摆脱严重的过拟合问题。针对这些问题，本研究将重点开展以下两个方面的研究工作：

(1) 针对复杂场景中的视频情感识别面临的独特挑战，本文提出一种新的基于注意力机制的双通路融合网络（Dual-path Fusion Network, DPFNet）。具体地，该网络采用双通路编码结构，以两条编码分支分别完成时序信息捕捉和复杂视觉嵌入约束。随后，通过注意力解码器与动态门控融合模块，突出关键情感信息并抑制噪声，最终实现单模态下的基于视觉内容的视频情感识别。在 VideoEmotion-8 和 Ekman-6 数据集上的实验结果表明，所提方法在保持相当情感识别准确率的前提下，仅依赖视觉模态输入即可实现更高效的识别，大幅降低了模型复杂度与计算开销。

(2) 针对复杂场景拍摄的视频样本情感标注稀缺导致过拟合的问题，本文提出一种基于辅助跨模态先验增强单模态情感建模的新范式，在不依赖多模态数据的前提下，有效利用模态共享语义与模态特定归纳偏置作为模型的先验知识。基于该范式，本文提出一种新的渐进式原型演化框架，通过与视觉线索的细粒度跨模态交互，将中性原型逐步转化为判别性情感表示，并将适应问题转化为情感空间内更易处理的原型迁移问题。为进一步保障原型构建与演化的稳健性，设计了类别聚合提示与双向监督机制。在 VideoEmotion-8、Ekman-6 和 MusicVideo-6 等多个数据集上的实验表明，本文方法取得了领先的性能，验证了利用辅助模态先验基于基础模型进行情感识别的有效性。

关键词：视频情感识别；迁移学习；视觉-语言模型

Abstract

Video emotion recognition involves analyzing and identifying emotions conveyed through multimodal information in videos, which has been widely applied in numerous fields such as education, security, and healthcare. Currently, most research on video emotion recognition focuses on emotion recognition based on multimodal signals generated by humans under controlled recording conditions. However, such methods still exhibit limited recognition performance and generalization ability when applied to videos captured in complex scenes, making effective application difficult. The inherent characteristics of complex scenes—such as unrestricted shooting techniques, diverse editing styles, and varied video content—pose significant challenges for emotion recognition, including dynamic changes in video content, diverse visual themes, and sparse emotional distribution. Additionally, the lack of large-scale emotionally annotated video datasets further restricts the training and performance improvement of related models, making it difficult for existing methods to overcome severe overfitting issues. To address these problems, this study focuses on the following two research directions:

(1) In response to the unique challenges of video emotion recognition in complex scenes, this thesis proposes a novel Dual-Path Fusion Network (DPFNet) based on an attention mechanism. Specifically, the network adopts a dual-path encoding structure, where two encoding branches capture temporal information and constrain complex visual embeddings, respectively. Subsequently, through an attention-based decoder and a dynamic gated fusion module, key emotional information is highlighted while noise is suppressed, ultimately enabling video emotion recognition based solely on visual content in a unimodal setting. Experimental results on the VideoEmotion-8 and Ekman-6 datasets demonstrate that the proposed method achieves comparable emotion recognition accuracy while relying only on visual modality input, significantly reducing model complexity and computational overhead.

(2) To address the overfitting issue caused by the scarcity of emotional annotations for videos captured in complex scenes, we introduce a novel paradigm that leverages auxiliary cross-modal priors to enhance unimodal emotion modeling, effectively exploiting

modality-shared semantics and modality-specific inductive biases without requiring multimodal data. Specifically, we introduce a progressive prototype evolution framework that gradually transforms a neutral prototype into discriminative emotional representations through fine-grained cross-modal interactions with visual cues. The auxiliary prior serves as a structural constraint and reframes the adaptation challenge from a difficult domain shift problem into a more tractable prototype shift within the affective space. To ensure robust prototype construction and guided evolution, we further design category-aggregated prompting and bidirectional supervision mechanisms. Extensive experiments on VideoEmotion-8, Ekman-6, and MusicVideo-6 validate the superiority of our approach, achieving the state-of-the-art results and demonstrating the effectiveness of leveraging auxiliary modality priors for foundation-model-based emotion recognition.

Key words: Video Emotion Recognition; Transfer Learning; Vision-language model

目 录

摘 要	i
Abstract	ii
第 1 章 绪论	1
1.1 视频情感识别的研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 视频情感识别的早期探索	2
1.2.2 基于深度学习的视频情感识别	3
1.2.3 复杂拍摄场景中的视频情感识别	5
1.3 本文研究内容	7
1.4 论文的组织结构	8
第 2 章 视频情感识别相关理论技术	10
2.1 多模态特征提取	10
2.1.1 视觉特征提取	10
2.1.2 文本特征提取	11
2.1.3 音频特征提取	11
2.2 特征处理技术	12
2.2.1 特征交互技术	13
2.2.2 多模态特征融合	14
2.3 CLIP 模型	14
2.3.1 Transformer 编码器概述	14
2.3.2 视觉编码器	16
2.3.3 文本编码器	16
2.3.4 训练方式	17
2.4 视频情感识别公开数据集	18
2.4.1 VideoEmotion-8 数据集	18
2.4.2 IEMOCAP 数据集	18
2.4.3 MELD 数据集	18

2.4.4 CMU-MOSI 数据集	19
2.4.5 CMU-MOSEI 数据集	19
2.5 本章小结	19
第 3 章 基于双通路融合网络的用户视频情感识别	21
3.1 引言	21
3.2 模型描述	22
3.2.1 整体框架	22
3.2.2 视觉特征和文本特征提取	23
3.2.3 双通路编解码网络	24
3.2.4 双路动态门控融合	26
3.2.5 情感预测与损失函数	27
3.3 实验结果与分析	28
3.3.1 数据集	28
3.3.2 实现细节	28
3.3.3 与最先进方法的对比	29
3.3.4 消融实验与分析	31
3.3.5 超参数实验和分析	34
3.3.6 案例分析	35
3.4 本章小结	38
第 4 章 基于渐进式原型演化的跨模态先验增强框架	39
4.1 引言	39
4.2 模型描述	40
4.2.1 时空编码模块	40
4.2.2 基于 Transformer 的解码器	41
4.2.3 原型衍生特征生成	42
4.2.4 类别聚合提示生成	42
4.2.5 双向监督	43
4.3 实验结果与分析	44
4.3.1 数据集	44

4.3.2 实现细节	44
4.3.3 与最先进方法的对比	45
4.3.5 提示敏感性分析	51
4.3.6 可视化分析	53
4.3.7 内存效率	53
4.4 本章小结	54
第 5 章 结论与展望	55
参考文献	57
攻读硕士学位期间取得的研究成果	64
致 谢	65

第 1 章 绪论

1.1 视频情感识别的研究背景与意义

情感与知觉、学习、记忆、言语是认知学中经典的认知过程，如何将这些认知过程及其相互作用在机器上实现已经成为当代计算机科学研究热点。构建一个可以对人类情感自动感知、识别、理解与反馈的可计算系统，是机器从认知客观世界到认知精神世界的跃迁，也是实现机器自然化、拟人化乃至人格化的基础性技术和重要前提，在智能助理、虚拟现实和智慧医疗等领域都有广泛的应用前景。

随着互联网视频资源的极大丰富，视频已然成为亟待发掘的宝藏，同时也催生出一系列对视频价值挖掘的分析方法。从传统的围绕标签、标题以及文本摘要进行的低成本分析策略，到深入视频内容开展的高价值分析决策，这些分析方法与检索、推荐算法相融合，衍生出视频平台的两大核心服务——内容推送和广告投送。但是这些分析方法未能实现从客观的物质层面需求到主观的情感层面需求的飞跃。简单来说，它们的结果忠实于内容，却无法高于内容；执着于统计概率，却鲜少“思考”人性。所以如何识别视频的情感倾向，是具备研究潜力的课题。

视频承载着视觉画面（如面部表情和手势）、语音内容（如字幕与旁白）以及声学信息（如人声与环境音）等多模态情感数据，为理解人类心理与社会动态提供了丰富的情感线索^[1]。大多数研究聚焦于受控录制条件下基于人体产生的信号对人类情感表达进行识别，例如在 CMU-MOSI^[2]、IEMOCAP^[3]等结构一致性较高的专业视频数据集上评估多模态融合模型对视频中人物的情感识别能力^[4-8]。尽管这些研究推动了基于多模态情感融合技术的视频情感识别的发展，但它们主要聚焦于视频中说话者本身的情感表达，而非揭示视频对观众产生的情感影响。复杂场景中的视频情感识别则会更侧重于识别由视频内容激发的观看者情感。对此类视频进行情感分析，不仅有助于研究者深入理解人类心理与社会行为机制，也在个性化推荐、内容审核及人机交互等应用中发挥重要作用。近期针对视频情感识别的综合性综述研究^[9]系统梳理了从经典方法到多模态大语言模型的完整演化路径，进一步印证了视频情感分析作为情感计算核心研究方向的重要地位。

与受控场景中录制的专业视频不同，由于自由的拍摄手法、迥异的剪辑风格和多样的视频内容，复杂拍摄场景中的视频情感识别通常包含更加复杂和多变的视觉内容。这

种复杂性给情感分析带来了三个主要挑战。首先，视频画面主题的多样性和情感表达的隐晦性使得低层视觉特征与高层情感语义之间存在显著的“情感鸿沟”^[10]，即低层视觉模式与高层情感语义之间的领域差异。其次，内容动态性强、场景切换频繁的问题会导致视频前后内容之间的关联度低，这使得建模长程的时序依赖关系变得尤为困难。最后，这类视频中情感分布极为稀疏，即表达特定强烈情感的帧或片段在整体视频中占比较低，大量中性内容或无关噪声的存在使得模型难以精准捕捉到真正关键的情感线索。除了上述这些主要挑战以外，缺少大规模情感标注视频数据集的问题进一步限制了相关模型的训练与性能提升。这使得现有方法难以摆脱严重的过拟合问题。针对这些问题与挑战，本研究将重点探索基于多模态知识的视频情感识别方法，进而提升复杂拍摄场景中视频情感识别的性能和效率。

1.2 国内外研究现状

情感识别是国内外备受关注的研究领域，已经走过一段较长的发展历史。顺应不同情感识别场景的需求，语音信号、心电信号、人脸表情以及其他生理信号等单一模态的情感识别已经取得了一定的进展。然而单一模态的情感识别容易受到数据采集环境的干扰，多模态的情感识别研究正日益受到学术界和工业界的重视，构建多模态情感识别系统已被认为是提高情感识别性能和鲁棒性的有效手段之一^[11]。然而从现实角度来看，虽然在长期的单一模态情感识别研究中产生了众多数据集，但是仍然缺少包含不同模态的数据集，唯有视频数据天然具备了视觉、音频、语言（语音识别）三种模态的信息，所以多模态情感识别领域的研究逐渐转向了视频场景。

1.2.1 视频情感识别的早期探索

De Silva^[12]等人最早探索在视频场景中使用多种模态决策的合理性，他们要求实验者从视频中分别通过视觉和音频来识别情绪，结果表明某些情绪（如悲伤和恐惧）通过听觉信息更容易识别，而其他情绪（如愤怒和快乐）则通过视觉信息更容易辨识。受此启发，Chen^[13]等人根据手工设计的声学 and 表情特征设计单模态分类器，通过融合单模态分类器的输出进行决策。Yoshitomi^[14]等人提出了一个多模态系统，他们认为传统摄像机采集面部表情时易受光照条件的影响，所以该系统不仅考虑了语音和视觉信息，还结合了通过红外摄像机获取的热分布信息。他们使用经验确定的权重在决策层面融合了这三种模态，使得系统的性能更佳。虽然早期围绕面部视觉信息决策的多模态识别取得了一

定进展,但是这些工作忽视了对肢体语言的建模。2008 年 IEMOCAP 情感数据集^[3]由美国南加州大学发布,数据采集内容包含音频、视频和文本信息,以及通过附加传感器收集的姿势信息,将人体姿态信息纳入了多模态情感识别的研究范畴。为帮助治疗罹患孤独症的儿童,文献^[15]提出了一种基于人体姿态的自动情感识别框架,该框架从一组 3D 骨骼运动序列中提取姿态、运动和几何特征,然后将这些特征输入到支持向量机中进行情感识别。Castellano^[16]等人同时使用了面部和手势特征来进行情感分析。为提取时间线索,研究者从运动时间特征曲线中得到主峰的初始斜率和最终斜率、主峰最大值与主峰持续时间的比值、平均值、平均值与最大值的比值等特征,超过了单一模态下的模型表现。然而上述这些面向实验室场景的方法有很大的局限性,例如针对脸部表情信息设计的手工特征需要人脸朝向特定的角度、人体在镜头中的位置要保持相对稳定,较为严苛的数据采集环境极大程度上限制了多模态系统的使用场景。

综上所述,视频情感识别的研究经历了从视觉听觉的两种模态的决策融合,到引入红外模态、身体姿态信息等补充模态,最后逐步扩展至对肢体语言的建模与分析。这条发展路径体现出研究者对于有利于情感识别的有效信息的持续探索和利用。但是此类方法大多依赖于手工设计的特征与受控的采集环境,在面部朝向、光照条件、人体位置等多个方面存在较多约束。这一问题限制了其在复杂拍摄场景中的应用与泛化能力。未来研究需进一步在真实、动态的场景下提升系统的识别能力。

1.2.2 基于深度学习的视频情感识别

随着深度学习的发展,研究者普遍认识到深度网络在提取鲁棒特征和多任务方面的潜力,这为拓展视频情感识别技术适应性、增强决策系统鲁棒性提供了新的契机。

Xu 等人^[17]设计了一种新颖的视觉情感预测框架,该框架基于在大规模目标检测数据集上预训练的卷积神经网络 (Convolutional Neural Networks, CNN) 实现物体识别,进而为情感识别提供辅助判别信息。但是由于预训练网络得到的语义特征和理想的情感特征之间存在着“情感鸿沟 (Affective Gap)”,物体识别的结果并不能稳健地提升模型决策能力。You 等人^[18]通过经微调的卷积神经网络提取视觉特征,并使用领域迁移学习来提高性能。这些工作反映了视觉信息提取从手工设计的局部特征向全局特征的转变,表情、姿态等潜在的视觉线索也能在同一个网络中成功捕获并相互作用。文献^[19]进一步提出一种使用在大规模情感图片数据集上学习到的领域知识编码视频特征的方法。他们借鉴了在自然语言中广泛使用的词袋特征表示方法,通过 Kmeans 聚类算法在辅助数据

集上确定聚类中心，将视频中的每一帧根据余弦相似度分配到最相似的聚类中心，统计帧数在这些聚类中心的分布并将该分布作为视频的特征向量。该方法展现了独特的零样本能力，但这种能力很大程度上来源于决策模型的时间不变性，即使调换帧之间的顺序也不会改变视频的词袋特征向量。然而情感线索的分布在时间上并非均匀的，它们可能集中分布在个别的片段中，隐藏在少数的动作、表情变化中，词袋向量表示方法无法对这些情感线索进行建模。为有效建模时空信息，Wollmer 等人^[20]将 OKAO Vision 提取到的音视频特征输入到双向长短期记忆网络（Bi-directional Long Short-Term Memory, BiLSTM）中进行特征级别的融合，而支持向量机（Support Vector Machine, SVM）则被用来获取文本模态的类别标签。最后，该方法使用加权求和的策略将 BiLSTM 和 SVM 的输出在决策层面上进行最终的融合。Poria 等人^[21]则开发了一种卷积循环神经网络来提取视觉特征。他们联合训练了卷积神经网络和循环神经网络（Recurrent Neural Network, RNN）。在多个多模态情感分析和情绪识别数据集上，他们的方法均优于当时的最先进技术。同一时期，3D 卷积网络也被成功应用于时空特征学习^[22]。与二维卷积网络相比，该网络被证明更适用于时空特征学习。在不同的实验设置中， 3×3 的卷积核是能够构建出最佳性能的架构，利用简单分类器学习到的特征在实验中超过了同等参数量下 CNN 和 RNN 结合的网络。在 EmotiW 2016 挑战赛中，Fan 和他的团队^[23]提出了一个混合网络，它以后期融合的方式结合了卷积循环神经网络和 3D 卷积网络。在 Fan 的设计中，RNN 和 C3D 以不同的方式编码外观和运动信息。具体而言，卷积循环神经网络将 CNN 从单个视频帧中提取的语义特征作为输入，随后编码动态语义信息，而 C3D 则专注于捕捉鲁棒的运动特征。结合音频模态，该系统在不使用训练集中除分类标签以外任何额外的情感标注数据的情况下，实现了 59.02% 的识别准确率，而此前 EmotiW 2015 挑战赛的获胜者准确率仅为 53.8%。实验结果表明，将 RNN 和 C3D 相结合可以显著提高视频情感识别的效果。

虽然各式各样的深度学习方法在不同模态中的均取得了长足的进步，直接促进了多模态情感问题的发展，但是在深度学习时代对于模态之间的特征融合也理应得到充分的探索。Mai 等人^[24]将沿时间维度对齐的多模态特征向量拼接后输送到 BiLSTM 中，为了解决 LSTM 在建模长距离时间关系不足的缺陷，他们引入了残差记忆网络来存储过去时间节点的重要信息。Zhang^[25]同样严格对齐视觉和音频模态的特征，但是采用了注意力机制在模态内和模态间两个层面建立隐式的联系。2017 年，Transformer 架构的问世，

随之而来的掩码自监督语言生成模型 BERT (Bidirectional Encoder Representations from Transformers) 和视觉 Transformer 框架在各自任务上均击败了当时主流的深度网络, 既验证了 Transformer 强大的任务适应能力, 也表明不同模态的数据都可以通过相似的方式编码成标记 (token) 的统一形式, 极大程度上方便了模态信息的交互。受到对比学习的启发, Mai 等人^[6]用对比损失取代了最大化互信息的训练目标, 核心思想是使得同样本的不同模态特征相互接近, 不同样本的相同模态特征相互远离, 使得模型具备更强的表示能力和统一的特征空间。最新的研究进一步将跨模态注意力机制与硬负样本挖掘策略相结合, 用于增强多模态情感特征的对齐与融合, 在对话场景的情感识别中也展现出良好的效果^[26]。

综上所述, 深度学习极大推动了多模态情感识别从依赖手工特征到学习深度表示的转变。但是这些进展大多基于一个共同的前提, 即情感状态会稳定、一致地外化为可观测的模态信号 (如表情、语调、姿态)。同时必须通过充分的数据驱动, 让模型能够学习到从这些信号到情感类别的映射。这一实现路径在现实世界中面临两大挑战。首先, 在数据稀缺或分布不均衡的场景下, 模型难以可靠地跨越“情感鸿沟”, 从而建立从多模态特征到复杂情感类别的映射。其次, 现有方法主要聚焦于解析情感主体的外在表现, 本质上是一种对视频中“说话者”的情感分析, 忽略了观众这个情感传递的最终对象的感知与接收效果。所以未来的研究有必要引入“观看者”的考量, 探索能够同时建模情感表达与情感感知的计算框架, 从而在更深层次上打通从多模态信号到情感语义的理解路径。

1.2.3 复杂拍摄场景中的视频情感识别

目前视频情感识别使用的技术方法与深度学习先进的研究成果联系密切, 从模态特征提取到多模态信息融合, 深度学习的影响力已经渗透到情感识别问题的各个方面。然而这一领域有很多问题尚未得到充分的解决。主流的视频情感数据集面向较为规整的受控录制条件下的视频场景, 比如面向演讲、评论场景的 CMU-MOSI 和 CMU-MOSEI^[27]数据集, 面向对话场景的 IEMOCAP 和 MELD^[28]数据集; 相应的复杂拍摄场景数据集包括面向用户视频 (User-generated Videos, UGVs) 场景的 Ekman6 和 VideoEmotion8 数据集。三种场景下识别任务的难度依次递增, 但是用户视频场景的数据集不仅规模无法与前二者相提并论, 相关研究比较保守地依据在其他数据集上效果先进的方法进行改进。用户视频场景更加贴近现实世界复杂环境中的拍摄情景, 为视频情感识别带来了视频内

容动态变化、画面主题多样、情感分布稀疏等挑战。目前的方法虽然针对这些挑战取得了一定的进展，但是在样本不足的情况下仍无法有效地建立多模态特征到情感特征的映射。

VAANet^[29]提出一种端到端的视频情感识别模型训练框架，首次提出使用 3D 卷积神经网络捕获视频中的时序特征、2D 卷积神经网络捕获音频频谱特征，并使用空间、通道和时序注意力处理多模态输入进行视频情感识别。TAM^[30]提出时间感知多模态方法，设计跨时段多模态融合模块以充分捕捉模态内与模态间的时间依赖关系，并创新性地利用时间同步评论作为辅助监督，通过两个自监督预训练任务从大规模无标注数据中学习视频片段的情感时序模式，在多个基准数据集上取得领先性能。Zhang 等^[31]利用无监督域自适应学习，结合情感图像数据集^[32]训练网络并获取与情感最相关的视觉特征。近期，CTEN^[25]通过挖掘关键片段之外的潜在上下文信息，创新性地提出时序擦除模块，擦除关键片段迫使模型从次相关片段中寻找情感线索。LRCANet^[33]为建模视频中的长程上下文相关性，提出时空相关性感知块，通过卷积层与图像间交叉注意力分别学习局部及长程时空关联。MPEM^[34]针对视频情感识别中多尺度时空特征的提取与融合问题，通过不同扩张率的卷积核分层捕捉从面部微表情到肢体动作的跨尺度特征，并结合动态特征适配器进行自适应的多源特征融合。然而，这些方法依赖在 ImageNet^[35]和 Kinetics^[36]上预训练的 CNN 模型，其预训练任务主要聚焦于使用 ID 标签的前景主体识别，忽视了标签文本和背景场景中隐藏的语义信息。

最近，视频理解任务（如动作识别）的最新进展探索了通过时序聚合模块将 CLIP^[37]迁移到视频任务的方法，主流方法是直接通过时序聚合模块将采样的图像特征映射到任务特定空间^[38,39]。这一成功实践主要得益于 CLIP 中常见动作描述与视觉语义能够在跨模态语义空间中轻易对齐。然而，由于情感鸿沟的存在，此类直接映射方法在视频情感分析中面临重大挑战。MM-VEMA^[40]首次迁移 CLIP 进行用户视频中的情感分析，但其依赖全参数微调策略，导致训练需要大量的显存开销。TE^[41]引入了多层堆叠的跨模态时序增强模块，展现了多层架构在视频情感识别中的有效性，但也因引入多个骨干网络牺牲了计算效率。尽管计算性能不够出色，这些工作也充分展现了视觉-语言模型在用户视频情感识别问题上的潜力。近期研究^[42]进一步探索了利用视觉原型引导跨模态特征对齐的新范式，通过从情感心理学中汲取原型理论的启发，引入类别级视觉情感锚点来约束多模态融合过程，取得了更具可解释性的识别效果。

研究进展显示，得益于时序建模机制的创新与视觉-语言模型的迁移应用，现阶段用户视频场景中的视频情感识别技术已实现显著突破，在一定程度上解决了复杂拍摄场景带来的三个严峻挑战。然而，当前研究仍面临双重制约。一方面，现阶段公开的用户视频场景数据集规模较小，不可避免地造成模型训练的过拟合问题；另一方面，视频的深度学习处理的复杂度远远高于图像和文本，在带来高昂训练成本的同时，也降低了视频情感识别的效率。未来的突破或需在追求更高效地利用视觉-语言先验知识的同时，降低模型复杂度以适应现实应用中视频情感识别对效率的要求。

1.3 本文研究内容

鉴于当前基于深度学习的视频情感识别方法的不足与复杂场景带来的挑战，本文深入具体问题，针对用户视频场景中的视觉模态数据，从两个角度提出创新性的解决方案。本研究主要围绕以下两个重点开展研究工作：

（1）针对复杂场景中的视频情感识别面临的独特挑战，本文提出一种新的基于注意力机制的双通路融合网络（DPFNet）。该方法利用强大的预训练视觉-语言模型 CLIP 所提供的语义对齐先验，借助多模态知识提升单模态模型的情感识别能力。具体而言，本文提出了一种双通路编码结构。其中主通路负责捕捉视觉序列的时序信息适应动态变化的视频内容，而辅助通路则通过情感辅助文本约束因为画面主题多样产生的复杂视觉嵌入。为了自适应地关注视觉嵌入中与情感高度相关的稀疏特征表示，本文采用基于注意力^[43]的解码器对双路信息分别解码。最后，通过一个动态门控融合模块聚合双路输出，从而在抑制噪声通道的同时突出关键情感信息。上述设计使 DPFNet 在本质上成为一种仅需视觉输入的高效模型。它通过视觉特征与少量固定的文本提示交互从而引入跨模态知识，无需依赖易缺失或低质量的音频信号，降低了对多模态数据的依赖，同时提高了识别效率。在 VideoEmotion-8 和 Ekman-6 数据集上的实验结果表明，所提方法在保持相当情感识别准确率的前提下，仅依赖视觉模态输入即可实现更高效的识别，大幅降低了模型复杂度与计算开销。

（2）针对复杂场景拍摄的视频样本情感标注稀缺导致过拟合的问题，本文提出一种基于辅助跨模态先验增强单模态情感建模的新范式，在不依赖多模态数据的前提下，有效利用模态共享语义与模态特定归纳偏置作为模型的先验知识。基于该范式，本文提出一种新的渐进式原型演化框架（PE-CLIP），通过与视觉线索的细粒度跨模态交互，

将中性原型逐步转化为判别性情感表示，并将适应问题转化为情感空间内更易处理的原型迁移问题。为进一步保障原型构建与演化的稳健性，设计了类别聚合提示与双向监督机制。在 VideoEmotion-8、Ekman-6 和 MusicVideo-6 等多个数据集上的实验表明，本文方法取得了领先的性能，验证了利用辅助模态先验基于基础模型进行情感识别的有效性。

1.4 论文的组织结构

本文主要研究基于多模态知识的视频情感识别算法，旨在高效利用多模态预训练模型中的先验知识应对复杂场景为视频情感识别带来的独特挑战，并且创新性地解决现有方法存在的问题。本文整体结构上共有五个章节，每个章节的安排如下：

第一章：绪论。本章系统地阐述视频情感识别的研究背景与意义，分析复杂场景下面临的关键挑战。同时本章梳理并评述国内外单模态与多模态情感识别方法的研究进展，总结现有工作的不足，进而明确本文的研究目标、主要内容与创新点。

第二章：相关理论与技术基础。本章围绕视频情感识别任务，系统介绍视觉情感特征提取、时序建模、注意力机制及跨模态表示学习等关键技术，重点阐述预训练视觉-语言模型（如 CLIP）的语义对齐机制及其在情感任务中的迁移潜力。同时，对知识蒸馏、原型学习等相关优化方法进行综述，并结合领域内常用数据集与评价指标进行系统性总结，为后续模型设计提供理论依据与技术支持。

第三章：基于注意力机制的双通路融合网络（DPFNet）。本章详细介绍所提出的双通路融合网络 DPFNet。首先阐述模型整体架构，包括基于 CLIP 的视觉-文本交互机制、双通路编码结构（主通路时序建模与辅助通路的文本引导约束）、基于注意力的解码设计以及动态门控融合模块；其次，通过对比实验验证 DPFNet 在 VideoEmotion-8 和 Ekman-6 数据集上的性能优势；接着，通过消融实验分析各模块贡献；最后，借助特征可视化等手段进一步说明模型在情感相关特征提取与噪声抑制方面的有效性。

第四章：基于渐进式原型演化的跨模态先验增强框架（PE-CLIP）。本章针对标注稀缺场景，提出一种渐进式原型演化框架 PE-CLIP。首先阐述该框架如何利用跨模态共享语义与模态特定归纳偏置作为先验知识，通过细粒度视觉-文本交互将中性原型逐步迁移为判别性情感表示；接着详细介绍类别聚合提示机制与双向监督策略的设计；最后，通过在 VideoEmotion-8、Ekman-6 和 MusicVideo-6 等多个数据集上的对比实验、模态重要性分析、参数敏感性检验等，全面验证所提方法的有效性与稳健性。

第五章：总结与展望。本章总结全文研究工作，归纳所提出的两种视觉情感识别模型（DPFNet 与 PE-CLIP）的核心思路与技术贡献，讨论其在降低模态依赖、提升模型效率与缓解标注稀缺问题方面的优势。同时，展望未来视频情感识别在动态场景适应、跨域泛化、轻量化部署等方面的可能研究方向。

第2章 视频情感识别相关理论技术

视频情感识别是多模态人工智能的重要研究方向，它的核心问题在于如何有效融合视觉、文本与音频等异构信息，以准确理解人类复杂的情感表达。本章系统梳理支撑该任务的关键理论与技术体系，重点围绕多模态特征提取、特征交互与融合机制展开，并深入介绍近年来具有代表性的跨模态预训练模型 CLIP 及其在情感理解中的潜力。同时，为支撑方法验证与性能评估，本章还综述了主流的视频情感识别公开数据集。本章的陈述内容为后续章节的模型设计与实验分析提供理论支撑与实践依据。

2.1 多模态特征提取

2.1.1 视觉特征提取

视觉特征提取的重要意义在于从视觉数据中提取有效信息以支持各类视觉任务。早期使用基于经典特征工程的视觉表征构建。这一技术依赖于人工特征设计，包括色彩直方图、纹理基元、形状轮廓等低阶视觉特征。例如，局部二值模式（LBP）借助相邻像素灰度值的差异能够对纹理进行编码，而灰度共生矩阵（GLCM）则通过二阶统计信息描述纹理的空间分布规律。此外，在视频情感分析中，也有研究尝试从运动时序曲线中提取特征，包括主峰的起始与结束斜率、峰值与时长之比、均值及其与峰值之比等指标。但是这类手工特征在视频情感识别的视觉特征提取中存在明显局限性。例如针对面部表情设计的手工特征通常要求人脸朝向固定、人体在画面中位置相对稳定，这类较为严苛的数据采集条件极大程度限制了多模态系统的实际应用场景。

随着深度神经网络结构的不断发展，卷积神经网络（CNN）与自注意力机制已成为学习图像表征的主要架构，它们通过堆叠非线性变换层次结构，自动学习如何从视觉信息中抽取出高层次的语义特征。早期研究采用预训练的 VGGNet^[44]与 ResNet^[45]等模型提取图像特征，进而实现情感分类。受自然语言处理领域成果的启发，基于 Transformer 的视觉模型 Vision Transformer（ViT）^[46]也被提出。该方法模仿文本中词向量的构建思路，先将图像分割为若干个图像块，再将其线性嵌入为向量序列，最终输入 Transformer 编码器进行特征学习。文献^[40]与文献^[41]采用基于 ViT 的预训练模型，在面向用户场景的视频情感识别任务中取得了显著进展。

2.1.2 文本特征提取

文本特征提取旨在将原始文本转化为计算机可处理且富含语义信息的数值化表示，是连接自然语言与情感计算的关键步骤。现有的技术方法大体可遵循其演进脉络分为两大方向：基于统计学的传统特征建模与基于深度学习的语义嵌入学习。

传统方法侧重于从词汇的统计规律中构造特征。其中，最为经典的词袋模型（Bag-of-Words）^[47]将文本视为词汇的集合，通过统计词频生成高维稀疏向量。虽然简单高效，但其忽略了词序与上下文，难以捕捉丰富的语义。为此，TF-IDF^[48]在词频基础上引入逆文档频率，赋予那些在特定文档中频繁出现、但在整个语料库中不常见的词汇以更高权重。这使其能够有效识别对文档（如产品评论）情感具有判别力的关键词，成为情感分析早期常用的特征构建手段。

然而，上述离散表示难以刻画词语间的语义关联。以 Word2Vec^[49]和 GloVe^[50]为代表的词嵌入技术，通过神经网络或无监督学习，将每个词映射为一个稠密的连续向量。这些向量构成的语义空间能够通过向量运算近似表达词语的语义相似性，缓解了稀疏向量带来的维度灾难。尽管静态词嵌入取得了可观的进步，但一个词的语义常随语境动态变化。为建模这种动态性，基于 Transformer 架构的预训练语言模型应运而生，它们能够生成上下文相关的词向量。例如，ELMo^[51]采用双向递归神经网络（Bi-LSTM）捕捉词汇的上下文信息；BERT 则利用 Transformer 编码器和掩码语言建模任务，以自监督的方式学习深层的双向语境表示，其在情感分类等下游任务上通过简单微调即可取得优秀的识别结果；GPT 系列模型^[52]采用单向 Transformer，在文本生成任务上表现卓越，也能用于情感导向的文本续写或生成。这些动态模型通过在大规模语料上进行预训练，显著提升了模型对文本中复杂情感语义的理解与表征能力，已成为当前情感分析研究中特征提取的主流范式。

2.1.3 音频特征提取

音频特征提取旨在通过计算模型解析声音信号中所蕴含的语义信息，其核心挑战在于如何从高维、动态且受个体差异影响的原始音频中，鲁棒地提取与任务高度相关的特征表示。当前的研究范式主要沿着两条技术路径演进：基于传统信号处理的“特征工程+分类器”范式，以及基于深度学习的“端到端”特征学习范式。

传统方法遵循明确的三阶段流程：信号预处理、人工特征提取与统计分类建模，其有效性高度依赖于领域知识。首先，原始语音信号需经过预处理以提升信噪比，包括静

音段切除、预加重、分帧加窗以及噪声抑制等步骤。随后，研究者设计并提取一系列低维声学特征参数。这些特征我们分为几种进行概括。韵律特征，如基频、能量、语速，反映情感表达的整体轮廓与节奏。音质特征，如谐波噪声比。频谱特征，如线性预测系数、过零率。其中，梅尔频率倒谱系数凭借其符合人耳听觉感知特性以及强大的音色表征能力，成为应用最广泛的情感特征之一。在特征提取后，通常采用高斯混合模型、支持向量机或隐马尔可夫模型等传统机器学习分类器完成情感状态的判别。尽管此类方法结构简单且在小规模数据集上得到有效性验证，其存在明显的局限性：难以适应情感音频的复杂性与模糊性；特征与分类器的分离式设计易造成信息损失；且对说话人的口音、年龄、性别等个体差异极为敏感，泛化能力受限。

深度学习通过构建多层非线性神经网络，实现了从原始数据（如波形或时频谱图）到情感标签的端到端映射，其核心优势在于能够自动学习数据的多层次、抽象表征，从而有效克服传统方法在特征设计上的瓶颈。深度学习在音频特征提取领域已形成从输入表征、网络架构到预训练范式的完整技术体系。梅尔声谱图等特征因符合卷积神经网络的图像处理范式，使得二维 CNN 能够高效提取与任务相关的局部时频模式。为进一步减少先验假设，研究转向以原始波形为起点的端到端学习，通过一维卷积核直接在时域提取基础特征，再结合循环神经网络或时域卷积网络建模长程依赖。当前的主流范式则由 Transformer 及其衍生架构所引领，通过自注意力机制对声谱图序列或子带信号进行全局上下文建模，以捕捉情感表达中的复杂动态过程；Conformer 等混合模型则进一步融合了 CNN 的局部建模优势与 Transformer 的全局建模能力。与此同时，以 Wav2Vec 2.0^[53]为代表的自监督预训练模型，通过在大规模无标注数据上构建掩码预测等代理任务，学习得到解耦的、富含语义的通用音频表征，为下游任务提供了强大的迁移基础。

2.2 特征处理技术

在完成特征提取后，需要将多模态高层语义特征映射到情感特征空间中，得到一个足够支持决策的判别表示。这个过程大体可以划分为两个子过程，分别是交互和融合。两者的区别在于，交互保持特征间相对独立，融合则将多个特征合而为一。所以融合通常建立在有效交互的基础之上。高质量的特征融合并非简单地将多个特征向量进行拼接或加和，而是需要先让它们进行充分而深入的对话与相互适应。通过交互过程，各模态特征能够相互查询、对齐和补充，揭示出单模态无法捕获的关联与协同信息。所以在多

模态视频情感识别中，交互是融合的 necessary 准备，而融合是交互的终极目标，两者共同确保最终的情感特征表示既保留了关键信息，又剔除了冗余与噪声，从而为后续的情感分类或回归决策提供鲁棒而有力的支持。

2.2.1 特征交互技术

在获得各模态的高层语义特征后，需要让它们进行有效的“对话”，以捕获跨模态间的协同、互补或矛盾信息。这个交互过程是生成判别性情感表征的关键。根据交互的机制和深度，主要技术可分为以下几类：

（1）顺序建模。顺序建模侧重于在时间维度上对特征序列进行交互。它假设情感的表达是一个动态演进的过程，各模态信息在时间线上相互独立。通常使用循环神经网络（RNN）及其变体，如长短期记忆网络（LSTM）和门控循环单元（GRU），来分别建模各模态特征的时序依赖关系。广泛用于捕捉情感随时间的演变规律，以及跨模态事件在时间上的先后、同步关系。

（2）基于张量运算的交互。基于张量运算的交互旨在通过高阶张量操作建模特征间复杂的组合关系。该方法的核心思想是，情感的表达往往源于不同模态信号的协同，其相互作用可能超越简单的线性叠加或拼接，呈现非线性、乘积式的耦合特性。为捕获这种深层次关联，经典方法通过计算不同模态特征向量的外积，构建一个高维张量，该张量理论上涵盖了所有可能的特征对之间的交互信息。然而，外积操作会直接导致维数灾难和巨大的计算开销。为解决此问题，研究实践中引入了多种高效的近似与优化策略，通过假设交互张量具有低秩特性，将高维张量分解为多个低维矩阵的乘积，从而在保留关键交互信息的同时大幅降低计算复杂度。

（3）基于注意力机制的交互。基于注意力机制的交互通过动态计算权重，实现对不同模态信息的自适应选择，是当前实现上下文感知交互的主流范式。其核心优势在于模拟了人类处理多源信息时的认知机制，即根据当前任务情境主动地从海量输入中筛选出最相关的部分进行处理。跨模态注意力允许一个模态去主动检索和加权聚合另一个模态中与之高度相关的片段，实现模态间的对齐与互补。同时注意力机制摒弃了传统的顺序建模的约束，允许序列中任意位置的特征直接进行全局交互，从而能够自主发现并整合远距离的模态内的和跨模态的依赖关系。近期的综合性综述^[54]对视频情感识别中的注意力机制与多模态融合策略进行了系统梳理，涵盖从传统方法到可解释 AI 框架的完整技术谱系。

2.2.2 多模态特征融合

多模态特征融合是指将来自文本、音频、视觉等不同模态的信息进行有效整合，以提升情感分析等任务的性能。根据融合阶段的不同，主要分为三类方法：

（1）早期融合（特征级融合）：在特征提取后直接拼接或映射各模态特征，形成统一的联合特征向量，再输入分类器。该方法能在早期实现特征交互，但面临异构特征对齐、时序同步与表征学习等挑战，适用于模态特征维度相近、时序对齐清晰的场景。

（2）晚期融合（决策级融合）：各模态先经独立分类器得到预测结果（如概率分布），再通过加权平均、投票或元分类器等方式进行集成。其优势在于允许模态专用模型设计，降低异构特征整合难度，且可通过集成降低整体误差；但可能丢失模态间细粒度交互信息，计算成本较高，常用于模态异构性强或噪声显著的任务。

（3）模型级融合：基于模态间关联性（如通过互信息、典型相关分析或深度学习进行量化），动态构建融合结构（如注意力机制、图网络），实现按任务需求与模态置信度自适应的特征整合与权重分配。该方法灵活性强，注重模态间的耦合关系与解耦表示，是当前多模态融合的重要研究方向。

总体而言，多模态融合方法的选择需综合考虑模态特性、任务需求与计算约束，早期融合强调低层特征交互，晚期融合侧重决策集成，而模型级融合则致力于实现关联感知的自适应融合。

2.3 CLIP 模型

CLIP（Contrastive Language-image Pre-training）由 OpenAI 于 2021 年提出，是一个通过自然语言监督学习视觉概念的跨模态预训练模型。其核心是将图像与相应的文本描述在特征空间中对齐，让模型学会理解图像内容与其对应文本描述之间的关联。CLIP 的创新在于采用了大规模的图像-文本对进行对比学习，从而获得了强大的零样本（zero-shot）迁移能力，无需针对特定任务进行微调，即可完成多种视觉识别任务。

2.3.1 Transformer 编码器概述

Transformer 是一种基于自注意力机制（Self-Attention Mechanism）的深度学习模型架构。它彻底摒弃了 RNN 和 CNN 在序列建模中的传统设计，完全依赖注意力机制来捕捉输入序列中的全局依赖关系。Transformer 的基于注意力的架构使其拥有强大的并行计算能力，在长序列任务的训练中表现出极高的效率。在 CLIP 模型的架构中，无论是视

觉编码器还是文本编码器，它们的主干网络均由 Transformer 编码器构成。Transformer 编码器的核心组件包括：

（1）位置编码。由于 Transformer 编码器不具备处理序列顺序的内在能力，所以必须显式地向输入嵌入中添加位置信息，再送入 Transformer 中。经典的位置编码采用一组具有不同频率的正弦和余弦函数来生成位置编码矩阵 $P \in \mathbb{R}^{n \times d}$ 与词嵌入相加，其中 n 为序列最大长度， d 为词向量的嵌入维度。位置编码矩阵 P 由以下公式计算：

$$P_{pos,2i} = \sin\left(\frac{pos}{10000^{2i/d}}\right) \quad (2-1)$$

$$P_{pos,2i+1} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (2-2)$$

其中， pos 表示词元在序列中的绝对位置，范围为 0 到 $n-1$ ； i 表示维度索引，其范围为 0 到 $d/2-1$ 。 i 增大，分母也随之增大，函数的波长变长，频率降低。通过让 i 遍历所有维度索引，模型能够使用从高频到低频的一系列正弦波来编码位置信息。这种位置编码的优点是能够外推到比训练序列更长的序列，且模型能学习到位置间的相对关系。还有一种可训练的位置编码的做法是将每个位置索引映射为一个可学习的向量参数。在训练过程中，模型自动学习最优的位置表示。这种方法更灵活，但通常受限于训练时见过的最大序列长度。在视觉任务中，由于图像块的数量固定，通常采用可学习位置编码提升任务适应性。

（2）注意力机制。注意力机制的核心是“缩放点积注意力”。对于一组由查询、键和值三个向量组成的输入，注意力函数通过计算查询与所有键的点积来衡量相关性，得到注意力权重矩阵，然后使用这些权重对值向量进行加权求和，从而生成一个聚焦于关键信息的输出。其基本运算可表述为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-3)$$

其中 Q 为查询， K 为键， V 为值， $W_q^{(h)}, W_k^{(h)}, W_v^{(h)} \in \mathbb{R}^{D \times d_k}$ 为第 h 个注意力头的投影矩阵， d_k 是 Q 的维度，防止点积值过大导致梯度消失。在引入多头并行计算后可实例化为多头注意力机制（Multi-head Attention, MHA）：

$$\text{MHA}(Q, K, V) = \text{Concat}_{h=1}^H \left(\text{Attention}\left(QW_q^{(h)}, KW_k^{(h)}, VW_v^{(h)}\right) \right) \quad (2-4)$$

其中 $W_q^{(h)}, W_k^{(h)}, W_v^{(h)} \in \mathbb{R}^{D \times d_k}$ 为第 h 个注意力头的投影矩阵, $d_k = D/H$, H 为注意力头总数。多头输出经拼接与线性投影后恢复至原始嵌入维度。多头计算使模型能并行关注不同语义子空间, 有效捕捉多样化的模式。

(3) 编码器模块的结构。一个标准的 Transformer 编码器是由若干个完全相同的层堆叠而成的。每一层通常包含两个核心子层, 每个子层都遵循“层计算 + 残差连接 + 层归一化”的设计, 这保证了深层网络的稳定训练。

2.3.2 视觉编码器

CLIP 的视觉编码器负责将输入图像转换为一个高维的特征向量。在 CLIP 的实验中, 研究者探索了两种主流的架构作为视觉编码器的基础。

(1) 基于 ResNet 的视觉编码器。采用经过修改的 ResNet 模型 (如 ResNet-50, ResNet-101 等), 将标准的全局平均池化层, 替换为一个基于自注意力的池化机制, 使其能够动态地关注图像中更重要的区域, 从而生成最终的图像特征表示。

(2) 基于 ViT 的视觉编码器。采用 ViT 架构。首先将输入图像分割成固定大小的图像块 (例如 16×16 像素), 将每个图像块线性投影为一个嵌入向量, 并添加可学习的位置嵌入。然后在这些嵌入序列前添加一个可学习的 [CLS] 标记 (分类标记), 并将整个处理后的序列送入标准的 Transformer 编码器。最终, 取 [CLS] 标记对应的输出向量作为整个图像的全局特征表示。

在 CLIP 的最终报告中, ViT 展现出了更优秀的性能和计算效率, 因此成为了 CLIP 首选的视觉编码器架构。它证明了纯 Transformer 结构在计算机视觉任务上的巨大潜力。

2.3.3 文本编码器

CLIP 的文本编码器负责将输入的文本描述转换为一个高维的特征向量。该编码器采用了基于 Transformer 的架构, 但根据 CLIP 的任务进行了优化。其处理流程为:

- (1) 输入文本被转换为子词单元 (例如使用 Byte Pair Encoding)。
- (2) 这些子词标记被转换为嵌入向量, 并添加位置嵌入。
- (3) 序列经过多层 Transformer 编码器进行处理。
- (4) 在序列的末尾添加一个特殊的 [EOS] 标记, 取该 [EOS] 标记在最后一层 Transformer 的输出作为整个文本序列的全局特征表示。

文本编码器的 Transformer 规模通常比视觉编码器小。其目标是捕捉语言的语义信息，并将其映射到与图像特征可对齐的共享特征空间中。

2.3.4 训练方式

CLIP 的核心创新在于其简单而有效的大规模对比学习训练范式。

(1) 训练数据。使用超大规模的图像-文本对数据集，例如从互联网上收集的 4 亿个 (400M) 图像及其对应的自然语言描述。数据的规模和多样性是 CLIP 获得强大泛化能力的基础。

(2) 对比预训练目标。在一个训练批次中，设有 N 个图像-文本对。图像编码器和文本编码器分别处理它们，得到 N 个图像特征向量 $I_1, I_2, \dots, I_N$ 和 N 个文本特征向量 $T_1, T_2, \dots, T_N$ 。其目标函数旨在最大化正样本对的相似度，将第 i 个图像 I_i 和其对应的第 i 个文本 T_i 构成正样本对，它们的特征点积应该尽可能高。同时最小化负样本对的相似度，第 i 个图像与批次中所有其他非对应的文本 $T_j (j \neq i)$ 构成负样本对，它们的相似度应该尽可能低。反之，对于第 i 个文本亦然。

(3) 损失函数。采用对称的交叉熵损失。对于每个图像 I_i ，将其与所有 N 个文本计算相似度，形成一个 N 分类问题，其标签为 i 。损失函数鼓励 I_i 与 T_i 的相似度远高于与其他 T_j 的相似度。同理，对于每个文本 T_i ，也将其与所有 N 个图像计算相似度，形成一个对称的 N 分类问题。最终的损失是图像到文本和文本到图像两个方向的对比损失的平均值。

(4) 零样本预测。训练完成后，CLIP 具备强大的零样本迁移能力。要执行一项新的分类任务将所有类别名称（如“狗”、“猫”、“汽车”）转化为自然语言提示（例如“一张 {类别} 的照片”）。文本编码器处理这些提示文本，得到每个类别的文本特征向量。对于待分类的图像，图像编码器提取其图像特征向量。然后，计算该图像特征与所有类别文本特征之间的余弦相似度。最后，将相似度最高的类别作为预测结果。这种训练方式使得 CLIP 不再受限于固定的封闭类别集，而是能够理解和响应开放词汇（Open-vocabulary）的视觉概念，为其在多模态理解、图像检索、零样本分类等领域的应用奠定了基础。

2.4 视频情感识别公开数据集

2.4.1 VideoEmotion-8 数据集

VideoEmotion-8 数据集^[55]是由 Jiang 等人构建的一个专注于用户视频情感识别任务的基准数据集，具有较高的研究参考价值。该数据集通过系统性采集互联网视频资源，涵盖电影片段、电视节目及在线视频平台内容等多元化来源，最终整合 8 种离散情感类别（愤怒、厌恶、恐惧、悲伤、惊讶、期待、信任与喜悦），共计 1101 个视频样本，总时长长达 12 小时的情感标注语料。数据集设计遵循 Plutchik 情感轮理论框架，将情感类别映射至心理学公认的基础情绪体系，确保类别划分具备充分的理论依据。在标注机制上，该数据集采用众包标注模式，通过多位标注者对同一样本进行独立评分并以投票机制确定最终标签，有效提升了情感标注的可靠性与一致性。VideoEmotion-8 的核心贡献在于系统验证了视频内容中视听融合特征对情感识别性能的提升效果，为多模态情感计算模型的跨场景泛化能力研究提供了重要的评测基准。

2.4.2 IEMOCAP 数据集

IEMOCAP（Interactive Emotional Dyadic Motion Capture）是由南加州大学 SAIL 实验室开发的一个多模态情感分析数据集，具有重要学术价值。该库通过双人交互的会话实验模式，系统采集包含语音信号、面部运动参数、视频流及人工转写文本的四维模态数据，总时长约 12 小时的高密度多模态语料。实验设计采用专业演员组（男女各 5 名）进行交叉组合，构建 5 组对话单元，每组会话均包含预设情景与自由发挥双阶段实验协议，有效激发被试者的真实情绪表达。该数据库的核心创新在于建立多维度情绪特征标注体系，除基础音视频文本数据外，创新性整合面部肌肉运动轨迹（涵盖微表情、头部姿态、手势动力学等非言语行为特征），经专业标注团队校验的细粒度标注数据为情绪计算模型提供跨模态分析基础。

2.4.3 MELD 数据集

MELD（Multimodal Emotion Lines Dataset）作为领域内标准数据库，其创新性在于构建时序动态情感标注体系。该库通过三元异构模态数据（文本序列、音频波形、视频流）的同步采集，完整记录 1,400 余组对话单元中 13,708 条有效话语样本，平均对话深度达 9.5 轮次。实验设计采用七维情感分类体系（愤怒、厌恶、悲伤等）与三维情感极性（积极/消极/中性）的双层标注框架，经专业标注团队交叉验证，标注者间一致性系

数 k 值达 0.73 ($p < 0.001$)。特别值得注意的是, 该数据库创新引入对话轮次间的情绪迁移标注, 可量化分析情感状态在时间维度的演化规律。

2.4.4 CMU-MOSI 数据集

CMU-MOSI (Carnegie Mellon University Multimodal Opinion Sentiment and Emotion) 是一个开源多模态情感分析数据集, 由卡内基梅隆大学开发, 旨在推动情感计算领域的多模态情感分析与理解。该库首次构建细粒度观点情感标注体系, 创新性地实现主观性强度 (0-5 级) 与情感极性 (积极/消极) 标注。实验语料来源于 YouTube 影评视频的专业筛选与分段处理, 共形成 2199 个独立观点表达单元, 累计有效时长 4.2 小时。实验群体包含 89 名发言人 (女性 41 名, 男性 48 名), 其自然状态下的多模态数据 (文本转录、面部微表情、语音韵律) 经严格对齐处理。基准测试表明, 基于该库训练的三模态融合模型在情感极性分类任务中的准确率达 82.7% (F1 值 0.81), 较最佳单模态基线提升 21.5 个百分点 ($p < 0.001$)。特别值得注意的是, 该库首次公开标注观点陈述中的情感强度衰减曲线, 为研究情感表达的动态变化机制提供关键数据支撑。

2.4.5 CMU-MOSEI 数据集

CMU-MOSEI (CMU Multimodal Opinion Sentiment and Emotion Intensity) 数据集是一个广泛应用于多模态情感分析研究的数据集, 由卡内基梅隆大学开发。作为 CMU MOSI 的拓展版本, 该数据库创新构建多维度细粒度情感标注体系: 在六元基础情绪分 17 广东技术师范大学学术硕士学位论文类 (喜悦、悲伤等) 基础上, 引入连续型情感强度标度 (-3 至 +3) 与多标签共存机制, 有效刻画复杂情感交互现象。实验数据经严格筛选来自 YouTube 平台的公开演讲视频, 经多模态时空编码技术处理后形成 23,568 个有效语料单元 (总时长 12.3 小时), 覆盖 250 个学科领域的 1,043 名发言人 (性别比例 1:1.02)。基准测试表明, 基于该库的三模态融合模型在情感极性分类任务中达到 89.4% 准确率 (F1 值 0.87), 较前代 CMU MOSI 提升 6.8 个百分点 ($p < 0.001$)。

2.5 本章小结

本章全面回顾了视频情感识别所依赖的核心理论与关键技术。首先, 分别从视觉、文本和音频三个模态详细阐述了从传统手工特征到深度学习驱动的特征提取方法演进。其次, 系统介绍了特征交互与多模态融合的主流范式, 包括顺序建模、张量交互、注意

力机制以及早期、晚期与模型级融合策略。然后，重点剖析了 CLIP 模型的架构原理、编码机制与对比学习训练方式，凸显其在跨模态语义对齐方面的优势。最后，汇总了 VideoEmotion-8、IEMOCAP、MELD、CMU-MOSI 及 CMU-MOSEI 等典型公开数据集的构建特点与标注体系，为算法验证提供了数据基础。整体而言，本章为构建高效、鲁棒的视频情感识别系统奠定了坚实的理论与技术基础。

第3章 基于双通路融合网络的用户视频情感识别

本章聚焦于如何有效解决复杂拍摄场景中的视频情感识别面临的挑战。针对视频中主题多样、内容动态变化、情感表达稀疏等问题，本文提出一种基于跨模态交互的双路融合网络（DPFNet），通过主辅双通路协同建模时序视觉特征与情感语义知识，并引入门控机制实现自适应特征融合。该设计不仅增强了模型对关键情感线索的捕捉能力，还在保证精度的同时兼顾了计算效率，为后续高效、鲁棒的多模态情感识别研究提供了新思路。

3.1 引言

用户视频场景给情感分析带来了三个主要挑战：首先，视频画面主题的多样性和情感表达的隐晦性使得低层视觉特征与高层情感语义之间存在显著的“情感鸿沟^[10]”，即低层视觉模式与高层情感语义之间的领域差异；其次，用户视频的内容动态性强、场景切换频繁，导致视频前后内容之间的关联度低，这使得建模长程的时序依赖关系变得尤为困难；最后，用户视频中情感分布极为稀疏，即表达特定强烈情感的帧或片段在整体视频中占比较低，大量中性内容或无关噪声的存在使得模型难以精准捕捉到真正关键的情感线索。

目前，用户视频情感识别的研究主要致力于解决情感鸿沟问题。其中一部分研究尝试通过直接增强视觉特征的情感语义丰富度，来获取更贴近情感层次的特征表示。然而，该方法严重依赖计算资源，由于深度架构中反向传播的运算需求，往往带来高昂的计算成本^[31]。一些工作通过设计可学习模块执行序列到序列映射来实现此目标，但相对简单的单层结构设计效果十分有限。TE^[41]引入了多层堆叠的跨模态时序增强模块，验证了多层结构在应对情感鸿沟和动态内容问题上的有效性，但也因引入多个骨干网络牺牲了计算效率。此外，视频中的情感表达往往取决于少数情感峰值，标准的编码器模型连续处理所有时序元素，可能稀释情感峰值的影响并引入情感无关的噪声。更重要的是，现有方法大多依赖于音频和视觉的多模态融合，这不仅增加了数据采集与处理的复杂性，在现实应用中，音频模态的缺失或质量低下也可能导致模型性能的急剧下降。

为了应对上述挑战，本文提出了一种基于跨模态交互的双通路融合网络（DPFNet）。该方法的核心思想是利用强大的预训练视觉-语言模型 CLIP 所提供的语义对齐先验，通

过预定义类别文本和辅助文本与视觉特征交互，引导模型从视觉模态中更精准地提取与情感相关的信息，借助多模态知识提升单模态模型的情感识别能力。具体而言，本文提出了一种双通路编码结构，其中主通路负责捕捉视觉序列的时序信息适应动态变化的视频内容，而辅助通路则通过情感辅助文本约束因为画面主题多样产生的复杂视觉嵌入。为了自适应地关注视觉嵌入中与情感高度相关的稀疏特征表示，采用基于注意力的解码器对双路信息分别解码。最后，通过一个动态门控融合模块聚合双路输出，从而在抑制噪声通道的同时突出关键情感信息。上述设计使 DPFNet 在本质上成为一种仅需视觉输入的高效模型。它通过视觉特征与少量固定的文本提示交互从而引入跨模态知识，无需依赖易缺失或低质量的音频信号，降低了对多模态数据的依赖，同时提高了识别效率。近期基于 CLIP 编码器的多模态情感识别方法也验证了利用标签文本嵌入增强情感特征表示的可行性，为视觉-语言语义知识向情感任务的迁移提供了新的技术路径^[56]。




图 3-1 基于双通路融合网络的视频情感识别框架

Figure 3-1 Video emotion recognition framework based on dual-path fusion network

3.2 模型描述

3.2.1 整体框架

针对用户视频画面复杂多样、时序动态变化显著以及情感线索分布稀疏等挑战，本文设计了一种新颖的双通路融合网络，整体框架如图 3-1 所示。该网络包含两条并行路

径：主路径通过自注意力机制建模原始视觉特征的时序依赖关系以适应动态变化的内容；辅助路径则通过交叉注意力机制引入固定的辅助文本嵌入来约束视觉特征在特定语义中表达，有效应对多样的画面主题。两条路径的输出通过共享参数的解码器进行并行解码，自适应地捕获稀疏的情感线索；通过门控融合机制动态地结合两条路径的信息，形成鲁棒的情感语义表征；最后，基于融合后的特征表示，通过计算相似度得分完成最终的情感分类。在公开数据集上的实验结果表明，所提方法有效提升了在用户视频场景下的情感分类性能。

3.2.2 视觉特征和文本特征提取

为了构建一个能够充分理解视频内容并关联语义情感的模型，分别从视觉与文本两个模态进行特征提取。模型采用 CLIP 模型作为特征提取器，以利用其在大规模跨模态预训练中获得的丰富先验知识，为跨越情感鸿沟提供坚实的语义基础。

（1）视觉特征提取

给定一个输入视频，首先将其采样为一系列帧，构成图像帧序列 $F_v = [f_1, f_2, \dots, f_T]$ ，其中 T 为序列长度。随后，将每一帧图像 f_t 送入一个冻结参数的 CLIP 视觉编码器中，通过预训练的 CLIP 视觉编码器提取视觉特征。具体而言，对于每一帧，取其最终层输出的 [cls] 标记作为该帧的帧级全局特征 $v_t \in \mathbb{R}^D$ 。最终，按照顺序嵌入可学习的位置编码向量^[46]后，得到整个视频的初始视觉特征序列 $V = \{v_1, v_2, \dots, v_T\} \in \mathbb{R}^{T \times D}$ ，其中 D 为特征维度。在此过程中，CLIP 视觉编码器的参数保持冻结，此举不仅显著提升了训练效率，有效防止了过拟合，同时确保了所提取特征的泛化性与稳定性

（2）文本特征提取

为了将情感类别语义信息引入模型，本文构建了一组基于情感类别的语义查询向量。具体地，将数据集中所有的 N 个情感类别名称（例如，VideoEmotion-8 中 8 个情感类别名称分别为“愤怒”、“期待”、“厌恶”、“恐惧”、“愉悦”、“悲伤”、“惊讶”、“信任”）逐个构造成文本提示（如“一个看起来令人感到[填充情感类别]的视频”），并送入冻结参数的 CLIP 文本编码器。与视觉特征提取不同，文本模态需要将排在文字标记后的 [end] 标记作为全局特征，最终将所有类别文本对应的 [end] 标记拼接得到查询向量 $E = [e_1; e_2; \dots; e_N] \in \mathbb{R}^{N \times D}$ 。同时必须指出，该查询向量包含了所有情感类别的信息，且对所有样本（包括训练集和测试集）保持一致，所以不存在对真值（Ground Truth）的泄露。此外，初始化一个可学习的全局上下文查询标记 e_{cls} ，旨在聚合整个视频的全

局上下文信息。最终，用于后续并行解码的查询向量 $Q^{(0)}$ 由 e_{cls} 与查询向量 E 拼接而成，可表示为 $Q^{(0)} = [e_{cls}; E] \in \mathbb{R}^{(1+N) \times D}$ 。该查询向量融合了全局表征与具体的类别语义，为解码器提供了明确的信息检索目标。如图 3-1 所示，查询向量 $Q^{(0)}$ 被分别送入主路径解码器和辅助路径解码器中与两路视觉嵌入进行跨模态交互，分别记作 $Q_m^{(0)}$ 和 $Q_n^{(0)}$ 以示区别。

同时，本文设计的辅助文本集合 $\mathcal{A}$ 共由九个短词汇构成，分别为“动物”、“场景”、“物体”、“自然”、“建筑”、“成人”、“儿童”、“男性”、“女性”。这些辅助文本是经过 GPT 归纳总结后，被认为能够囊括大部分用户视频内容的词汇概念集合。通过 CLIP 文本编码器对集合 $\mathcal{A}$ 中的词汇分别处理获取对应的辅助文本嵌入，这个过程和构建语义查询向量类似，但不同点在于辅助文本嵌入不受数据集的影响，在实验中所用的两个数据集上保持一致。最终得到嵌入集合 $A = [a_1; a_2; \dots; a_9] \in \mathbb{R}^{9 \times D}$ 。如图 3-1 所示，在交叉注意力模块中，这些辅助文本嵌入根据与视觉嵌入 V 的相关性进行加权求和，进而将多样的视觉嵌入约束在少量嵌入构成的语义空间中，从而缓解视频内容多样导致识别困难的问题。

3.2.3 双通路编解码网络

(1) 多头注意力机制

所提编解码网络的设计核心是注意力机制，其基本运算可表述为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3-1)$$

在引入多头并行计算后可实例化为多头注意力机制（Multi-head Attention, MHA）：

$$\text{MHA}(Q, K, V) = \text{Concat}_{h=1}^H \left(\text{Attention}\left(QW_q^{(h)}, KW_k^{(h)}, VW_v^{(h)}\right) \right) \quad (3-2)$$

其中 Q 为查询， K 为键， V 为值， $W_q^{(h)}, W_k^{(h)}, W_v^{(h)} \in \mathbb{R}^{D \times d_k}$ 为第 h 个注意力头的投影矩阵， $d_k = D/H$ ， H 为注意力头总数。多头输出经拼接与线性投影后恢复至原始嵌入维度。多头计算使模型能并行关注不同语义子空间，有效捕捉多样化情感线索。当特化为多头自注意力（Multi-head Self-attention, MHSA）时，查询、键和值均来自同一输入序列 X ，即 $Q = K = V = X$ 。所以多头自注意力表达如下：

$$\text{MHSA}(X) = \text{MHA}(X, X, X) \quad (3-3)$$

当特化为多头交叉注意力时，查询来自输入序列 X ，键和值来自另一序列 Y ，即 $Q = X$ ，

$K = V = Y$ 。所以多头交叉注意力（Multi-head Cross-attention, MHCA）表达如下：

$$\text{MHCA}(X, Y) = \text{MHA}(X, Y, Y) \quad (3-4)$$

（2）双路注意力编码

由于视频的视觉信息是动态变化的，仅对单帧级别的视觉嵌入进行独立处理难以捕捉诸如运动、场景转换等时序层面的信息。为此，主编码路径旨在建模原始视觉嵌入之间的时序依赖关系，通过自注意力机制捕捉视频帧间的时序关联：

$$V_m = \text{MHSA}(V) \quad (3-5)$$

其中， V_m 表示原始视觉嵌入 V 经过主路径中多头自注意力编码后得到的结果。另一方面，在情感识别任务中，同类别的样本之间常存在显著的内容差异，即便在同一视频中也会出现拍摄场景切换或用户多次剪辑，容易造成画面内容与主题的剧烈变化。为应对这一问题，本文设计了辅助编码路径，通过引入少量固定的辅助文本嵌入，并借助交叉注意力机制对视觉特征进行语义层面的重构，从而将多样的视觉嵌入约束于辅助文本所定义的语义空间中：

$$V_n = \text{MHCA}(V, A) \quad (3-6)$$

其中， V_n 表示以原始视觉嵌入 V 作为查询，以辅助文本嵌入 A 作为键与值，通过多头交叉注意力机制重构后得到的视觉表示。该机制使模型能够聚焦于与视觉内容高度相关的语义概念，从而保障在语义空间中进行重构的合理性与有效性。

（3）双路注意力解码

为承接并融合双路编码器输出的异构特征，本文设计了一种基于语义查询向量的双路解码器。该解码器通过两条并行的路径，分别与主路径特征 V_m 和辅助路径特征 V_n 进行深度交互，最终通过动态门控融合机制生成鲁棒的情感语义表征。

如图 3-2 所示，解码器的核心是由 L 个堆叠的 Transformer 解码块（Transformer Decoder Block, TDB）构成。每个解码块包含自注意力、交叉注意力和前馈网络三个核心组件，并均辅以残差连接与层归一化来保障训练的稳定性。在第 l 个解码块中，语义查询向量 $Q \in \mathbb{R}^{(N+1) \times D}$ 的更新过程如下：

$$Q' = \text{LN}\left(Q^{(l-1)} + \gamma_1 \odot \text{MHSA}^l(Q^{(l-1)})\right) \quad (3-7)$$

$$Q'' = \text{LN}\left(Q' + \gamma_2 \odot \text{MHCA}^l(Q', V_x)\right) \quad (3-8)$$

$$Q^{(l)} = \text{LN}\left(Q'' + \gamma_3 \odot \text{FFN}^l(Q'')\right) \quad (3-9)$$

式中, $\gamma_1, \gamma_2, \gamma_3 \in \mathbb{R}^D$ 为可学习的残差连接缩放系数, 初始化阶段置零使公式 7~9 接近恒等映射, 在训练过程中逐渐学习到合适的缩放比例, 利于深层网络的训练; LN 表示层归一化计算 (Layer Norm); $\odot$ 表示逐元素进行乘积运算; V_x 代表输入该解码器的视觉嵌入 (即 V_m 或 V_n)。自注意力层促进了语义查询向量间的内部交互, 以建立全局的语义上下文。随后的交叉注意力层则使语义查询能够有选择地从对应的视觉特征路径中捕获相关信息。此外在前馈网络 (Feed Forward Network, FFN) 中, 采用高斯误差线性单元 (Gaussian error Linear Units, GELU) 作为激活函数, 其表达式如下:

$$\text{GELU}(x) = x \cdot \Phi(x) \quad (3-10)$$

式中, $\Phi(x)$ 是标准高斯分布的累积分布函数。与标准的 ReLU 函数相比, GELU 通过其随输入值变化的随机正则特性, 提供了更平滑的非线性变换, 这有助于模型更细致地建模复杂的情感表达, 并在深层网络中缓解梯度消失问题。

在双路解码框架中, 两条路径独立且并行地处理视觉嵌入, 主路径对应 V_m , 辅助路径对应 V_n :

$$Q_m^{(l)} = \text{TDB}^l(Q_m^{(l-1)}, V_m) \quad (3-11)$$

$$Q_n^{(l)} = \text{TDB}^l(Q_n^{(l-1)}, V_n) \quad (3-12)$$

值得注意的是, 两条路径中的 TDB 采用共享参数的设计。此举一方面能显著减少模型参数量, 防止过拟合; 另一方面, 它迫使同一个处理模块学会同时理解原始视觉时序依赖和语义约束后的视觉特征, 从而学习到更具泛化性的情感感知模式。经过 L 层解码块的处理后, 最终获得了两组富含不同视角信息的语义查询输出 $Q_m^{(L)}$ 和 $Q_n^{(L)}$ 。随后通过一个可学习的门控权重对它们进行自适应融合, 形成足够支持情感决策的表征。

3.2.4 双路动态门控融合

为自适应融合两条路径的信息, 本文设计了动态门控融合机制。首先对辅助路径输出进行投影并应用门控函数, 主路径保留主要信息不做处理:

$$Q_n = \sigma(W_g[Q_n^{(L)}; Q_m^{(L)}]) \odot (W_p Q_n^{(L)}) \quad (3-13)$$

$$Q_m = Q_m^{(L)} \quad (3-14)$$

其中: σ 为 GELU 函数, 相较于 Sigmoid 函数具有更灵活的调节范围, 可以同时实现特征增强和噪声抑制; W_g 和 W_p 为可学习参数。

考虑到两条路径特征范数的差异，引入自适应缩放因子。对于每个位置的特征向量，计算其对应的缩放因子：

$$\alpha_i = \min(1, \frac{\|Q_m^i\|_2}{\|Q_n^i\|_2}) \cdot w \quad (3-15)$$

其中 Q_m^i 和 Q_n^i 分别表示 Q_m 和 Q_n 在位置 i ($i \in \{0, 1, \dots, N\}$) 的特征向量， $\|\cdot\|_2$ 表示向量的 L2 范数， w 为可学习的缩放系数。令 $\alpha = [\alpha_0, \alpha_1, \dots, \alpha_N]^T$ 表示由所有位置缩放因子组成的向量，其中 N 为空间位置总数（同时也是类别数量）。最终融合结果为：

$$Q_f = Q_m + \alpha \odot Q_n \quad (3-16)$$

该门控机制允许模型根据具体的输入内容，动态地权衡原始视觉时序特征与辅助文本约束特征对最终情感识别任务的相对重要性。这种设计使得模型能够在保持主路径稳定性的同时，有效利用辅助路径提供的补充信息，抑制无关通道表达，从而缓解深层网络的过拟合问题，提升模型对复杂情感模式的建模能力。




图 3-2 基于注意力机制的解码器设计

Figure 3-2 Design of decoder based on attention mechanism

3.2.5 情感预测与损失函数

从融合后的查询向量 $Q_f = [e_{cls}; E] \in \mathbb{R}^{(1+N) \times D}$ 分离出全局查询标记 e_{cls} 和情感类别标记集合 E ，分别进行 L2 范数归一化后计算相似度得分 $y \in \mathbb{R}^N$ ：

$$y = \frac{e_{cls} E^T}{\tau} \quad (3-17)$$

其中: τ 为温度参数。为了将相似度得分 y 转换为情感类别的概率分布, 使用 Softmax 函数进行处理:

$$p_i = \frac{\exp(y_i)}{\sum_{j=1}^N \exp(y_j)} \quad (3-18)$$

其中: $p \in \mathbb{R}^N$ 是一个表示概率的向量, 其每个元素 p_i 表示查询标记 e_{cls} 属于第 i 个情感类别的预测概率。在训练过程中, 为了优化模型参数, 采用交叉熵函数进行损失计算。

3.3 实验结果与分析

3.3.1 数据集

与先前研究相同, 本文在 VideoEmotion-8 数据集和 Ekman-6^[19]数据集上评估所提方法。VideoEmotion-8 数据集包含从视频网站 (YouTube 和 Flickr) 采集的 1,101 个视频, 标注有八种情感类别, 平均时长 107 秒。为与现有工作公平比较, 以开源数据集规定的划分方式进行十次 2:1 训练-测试划分的实验, 取所有实验的平均准确率。类似地, Ekman-6 数据集包含 1,637 个来自 YouTube 和 Flickr 的视频, 标注有六种基本情感, 平均时长 112 秒。两个数据集包含的具体情感类别在表 3-1 中展示。本文遵循先前研究使用的 1:1 训练-测试划分配置, 并采用不同随机种子进行实验取平均准确率作为对比指标。

表 3-1 数据集信息
Table 3-1 Dataset information

数据集名称	样本数量	类别标签
VideoEmotion-8 (VE-8)	1101	“愤怒”、“期待”、“厌恶”、“恐惧”、“愉悦”、“悲伤”、“惊讶”、“信任”
Ekman-6 (EK-6)	1637	“愤怒”、“厌恶”、“恐惧”、“愉悦”、“悲伤”、“惊讶”

3.3.2 实现细节

每个视频被划分为 16 个连续的非重叠时序片段。在训练阶段, 从每个片段中随机采样一帧; 评估阶段则采用每个片段的中心帧采样以确保可复现性。空间归一化方面, 每帧图像被调整为 224×224 分辨率, 推理期间通过中心裁剪保持宽高比。为缓解训练过拟合, 本文采取简单的数据增强策略, 通过随机缩放裁剪 (尺度参数采样自区间 [0.64, 1], 宽高比限制在区间 [3/4, 4/3]) 进行图像变换。需要注意的是, 同一视频序列中的所有图

像采用相同的空间裁剪坐标以保持数据增强在时间上的一致性。DPFNet 采用 CLIP B/32 作为骨干网络提取帧级别的视觉特征，其中的多头注意力模块均采用 512 维的嵌入维度和 8 个注意力头设置。此外经过超参数网格搜索，将温度超参数 τ 设为 0.01，解码块 L 的数量设为 4。

优化方面，本文采用 Adam 优化器，使用 $2e-4$ 学习率训练 50 个周期，批次大小为 16。所有实验均遵循情感识别标准评估实践，采用单标签情感分类方法，性能通过 Top-1 准确率（%）量化。

3.3.3 与最先进方法的对比

（1）对比方法

a) ITE^[19]: 通过引入外部情感图像数据集的知识，设计图像迁移编码算法，将帧级别特征聚合为具有情感语义的视频级别表示。

b) VAANet^[29]: 首次提出使用 3D 卷积神经网络捕获视频中的时序特征、2D 卷积神经网络捕获音频频谱特征，是用户视频情感识别领域内第一个端到端学习的深度网络。

c) TAM^[30]: 提出时间感知多模态方法，设计跨时段多模态融合模块以充分捕捉模态内与模态间的时间依赖关系，并创新性地利用时间同步评论作为辅助监督，通过两个自监督预训练任务从大规模无标注数据中学习视频片段的情感时序模式，在多个基准数据集上取得领先性能。

d) CTEN^[25]: 在 VAANet 基础上创新性地提出时序擦除模块，通过擦除关键片段迫使模型从非关键片段中寻找情感线索，挖掘关键片段之外的潜在上下文信息。

e) IFPN^[31]: 与 ITE 相似，引入外部情感图像数据集并获取与情感最相关的视觉特征。不同点在于 IFPN 创新性地采用生成对抗网络，通过混淆情感图像数据和视频帧图像数据实现无监督域自适应学习。

f) LRCANet^[33]: 为建模视频中的长程上下文相关性，提出时空相关性感知块，通过卷积层与图像间交叉注意力分别学习局部及长程时空关联。

g) MPEM^[34]: 针对视频情感识别中多尺度时空特征的提取与融合问题，通过不同扩张率的卷积核分层捕捉从面部微表情到肢体动作的跨尺度特征，并结合动态特征适配器进行自适应的多源特征融合。

h) MM-VEMA^[40]: 首次提出将 CLIP 模型应用于用户视频情感识别，以全参数微调的方式在多个基准数据集上取得领先性能。

i) TE^[41]: 将离散采样的帧图像序列视为除连续视频和音频之外的第三种模态输入, 并设计跨模态时间增强模块以同时交互多模态信息, 强调关键时间片段并抑制无关信息, 实现了先进性能。

(2) 分类识别能力

本文在表 3-2 中将 DPFNet 与其它先进方法在 VideoEmotion-8 和 Ekman-6 数据集上进行了比较。表格中“模态”一列的“V”代表接受视觉模态输入, “A”代表接受音频模态的输入; “扩充数据”一项被勾选的方法代表着其使用了外部的数据集辅助训练或者决策。与先前的用户视频基准相比, 所提框架的优越性尤为明显。所提 DPFNet 分别在这两个数据集上取得了 60.2%和 63.7%的 Top-1 准确率, 这个分数超越了除 TE 模型外其他的所有方法。值得注意的是, 虽然 TE 在用户视频基准上取得了有竞争力的结果, 但所提架构在 VE-8 上实现了+0.4%的性能提升, 在 EK-6 数据集上也表现出与 TE 相当的性能。同时 TE 接受三模态输入, 分别使用了三种骨干网络形成了参数量庞大的总体网络, 这意味着 DPFNet 使用了更少的模态输入以及更少的模型参数, 展现了 DPFNet 在用户视频情感理解方面的卓越效率。

表 3-2 与最先进方法的对比实验
Table 3-2 Comparison with state-of-the-art approaches

模型	发表刊物	模态	扩充数据	Top-1 准确率 (%)	
				VE-8	EK-6
ITE	TAC'16	V+A	√	52.6	55.6
VAANet	AAAI'20	V+A		54.5	55.3
TAM	ACM MM'22	V+A	√	57.5	61.0
CTEN	CVPR'23	V+A		57.3	58.2
IFPN	TMM'23	V	√	57.6	60.4
LRCANet	IET IP'24	V+A		57.4	59.8
MPEM	Electronics'25	V+A		57.6	61.3
MM-VEMA	PRCV'23	V		59.4	62.8
TE	ACM MM'24	V+A		59.8	64.8
DPFNet	Ours	V		60.2	63.7

(3) 模型效率分析

首先对表 3-3 中的度量单位和设置进行必要的解释。表格中“可训练参数量”和“显存使用量”的度量单位分别为 MB 和 GB；“输入帧数”一栏统一形式为 $S \times F$ ，实际意义为将视频切分为不重叠的 S 个片段，每个片段采样 F 帧。如表 3-3 所示，尽管更简单的编码器方法 VAANet 能够与 DPFNet 在模型效率方面相当，可训练参数量和显存使用量均仅高于所提 DPFNet，但该方法在识别性能上远落后于现阶段最先进方法的性能。在识别表现较优的方法中，DPFNet 表现出较低的计算需求。目前识别准确率最高的 TE 方法的可训练参数量是所提 DPFNet 的十倍，其采用多层跨模态时序增强模块经过训练以增强模态间相关性，但需要比其他任何方法都多的计算资源。相比之下，DPFNet 保持在较少可训练参数的同时实现了最先进的性能，在计算需求和模型效果之间建立了最佳平衡。

MM-VEMA 在处理相同数量的输入帧时，需要大约 3 倍于 DPFNet 的显存容量。相比之下，同样是单模态方法的 DPFNet 是模型效率更高的架构，因为其采用冻结的预训练主干网络，同时仅训练部分模块。这种模型效率和识别准确率的优势使 DPFNet 方法有望成为在线视频情感理解等现实应用的理想选择。

表 3-3 模型效率对比
Table 3-3 Model efficiency comparison

模型	可训练参数量	模态	输入帧数	显存使用量
VAANet	48.2	V+A	8×16	6.9
CTEN	202.9	V+A	8×16	12.5
MM-VEMA	577.1	V	16×1	16.4
TE	386.3	V+A	8×16	17.9
DPFNet	38.7	V	16×1	5.4

3.3.4 消融实验与分析

为验证本文提出的双路融合网络中各组件的有效性，本文在 VideoEmotion-8 数据集上进行了系统的消融实验。所有实验均采用相同的训练策略和超参数设置，以确保比较的公平性。

（1）关键组件有效性分析

表 3-4 展示了双路融合网络中关键组件的消融结果，表格中的短划线表示仅使用单路特征的情况下相应设置无讨论意义。首先，仅使用主路径时，模型在 VideoEmotion-8

数据集上的平均准确率为 57.3%，表明基于自注意力的时序建模能够有效捕捉视频帧间的情感依赖关系。单独使用辅助路径时，由于缺乏原始视觉信息和时序信息共同导致的情感线索丢失，性能略微下降至 55.8%。

当同时使用主路径和辅助特征经过共享参数的双路解码器解码但未引入门控融合时（简单加和），性能显著提升至 58.8%，验证了主路径和辅助路径特征具有互补的特性，同时也表明辅助路径编码可通过约束视觉语义表达从而提升模型的识别效果。最后，引入本文提出的门控融合机制后，模型达到最佳性能（60.2%），验证了自适应特征融合能够更有效地从辅助路径中提取和主路径互补的信息。

关于解码器参数共享是否会真实地影响识别效果，在表格中最后一行反映了主路径和辅助路径分别采用两个独立的解码器时模型的表现。在增加了额外的模型参数的同时，模型的性能略微下降，反映出模型无法有效利用两条路径中共通的解码规则，验证了共享参数设置的合理性。

表 3-4 关键组件消融实验
Table 3-4 Ablation study on main components

主路径	辅助路径	门控融合	解码器参数共享	准确率
√	×	-	-	57.3
×	√	-	-	55.8
√	√	×	√	58.8
√	√	√	√	60.2
√	√	√	×	59.4

（2）时序编码模块分析

表 3-5 比较了不同时序编码方法在 DPFNet 中的表现。实验方式为，将主路径的原时序编码方法替换为时序建模任务中常见的几种方法。实验结果表明，基于 Attention 的原方法分别在 VideoEmotion-8 和 Ekman-6 数据集上取得 60.2%与 63.7%的最佳性能。传统的 GRU 和 BiLSTM 方法由于长程依赖建模能力的限制，性能相对较低。与结果相对较优的 GRU 相比，Attention 在两个数据集上的准确率分别提升 1.6 与 1.1 个百分点。与不采用任何时序编码方法（即恒等映射 Identity 层）相比，准确率分别提升 3.0 和 3.8 个百分点，验证了所提基于 Attention 的时序编码模块的有效性。

表 3-5 时序编码方法有效性分析
Table 3-5 Analysis of the effectiveness of temporal encoding methods

时序建模方法	VideoEmotion-8	Ekman-6
Identity	57.2	59.9
BiLSTM	58.2	62.1
GRU	58.6	62.6
Attention	60.2	63.7

(3) 辅助文本集合规模的敏感性分析

为探究辅助文本集合规模对模型性能的影响，本文设计了规模分别为 5、9、15 的三组词汇进行对比实验。其中，规模为 9 的词汇集合为原文设定，作为基准集合，覆盖“人物”、“场景”、“物体”等高层语义类别；规模为 5 的词汇集合为基准集合的子集，聚焦于非人物类别，仅保留“动物”、“场景”、“物体”、“自然”、“建筑”这五个词汇；规模为 15 的词汇集合则在基准集合的基础上扩展了“光线”、“食物”、“植物”、“景观”、“废弃物”、“艺术品”六个词汇。在 VideoEmotion-8 和 EKman-6 数据集上的实验结果如表 3-6 所示。实验表明，规模为 9 时模型取得最佳性能。规模减小会导致语义覆盖面存在不足，规模增大则可能引入冗余信息，反而轻微降低识别效果。该结果说明，当前所选 9 个词汇在表达丰富性与模型泛化能力之间达到了较好平衡，同时间接验证了基准词汇集合设置的合理性。

表 3-6 辅助文本集合规模的敏感性分析
Table 3-6 Sensitivity analysis of auxiliary text set size

词汇规模	VideoEmotion-8	Ekman-6
5	58.1	62.2
9	60.2	63.7
15	59.9	63.5

(4) CLIP 参数微调策略分析

大规模视觉-语言预训练模型的参数更新策略是影响下游任务性能的关键。为探究不同策略对 DPFNet 的影响，并验证完全冻结策略的合理性，本文设计了一组针对不同参数微调策略的消融实验。以原文设定的“完全冻结 CLIP 视觉与文本编码器”作为基线，分别对视觉编码器和文本编码器进行不同程度的解冻微调。具体策略包括：微调最

后一层、微调最后两层（第 11-12 层）、微调最后四层（第 9-12 层）以及微调全部参数。不同微调策略在 VideoEmotion-8 数据集上的性能对比如表 3-7 所示。实验结果表明，完全冻结 CLIP 编码器参数是效果最好的设置，任何程度的微调都会导致性能下降，且解冻层数越多，性能衰退越显著。对视觉编码器进行微调造成的性能下降极为严重，在完全微调情况下将导致准确率下降 35.0%。经过分析其原因主要在于训练数据规模有限，微调参数量巨大的 CLIP 模型极易引发过拟合。所以保持 CLIP 参数冻结，能够最有效地利用其先验知识，确保模型在情感识别任务上的鲁棒性能。

表 3-7 CLIP 参数微调策略分析
Table 3-7 Analysis of CLIP parameter fine-tuning strategy

微调目标	策略	准确率
--	全部冻结	60.2
视觉编码器	微调第 12 层	55.2
	微调第 11-12 层	48.9
	微调第 9-12 层	33.1
	微调全部参数	25.2
文本编码器	微调第 12 层	59.8
	微调第 11-12 层	57.7
	微调第 9-12 层	53.6
	微调全部参数	44.2

3.3.5 超参数实验和分析

（1）解码块数量

解码块数量 L 决定了模型处理视觉与文本特征交互并进行推理的容量。本文在 $L \in \{2, 4, 6, 8\}$ 的范围内进行实验。如图 3-3 所示，当 $L = 4$ 时，模型在 VideoEmotion-8 数据集上达到 60.2% 的最高准确率。当 $L = 2$ 时，模型分类能力受到明显限制；当 L 增加至 6 乃至 8 时，模型表现出性能的轻微连续下降，这可能是因为在有限数据下，更深的网络引发了轻微的过拟合和优化困难。所以将 L 设置为 4 是模型表现与参数量之间的一个理想平衡点。




图 3-3 解码块数量对模型分类性能的影响

Figure 3-3 The impact of decoding block quantity on model classification performance

（2）温度系数

温度系数 τ 在公式 (15) 中用于缩放相似度得分，控制预测分布的平滑度。在 CLIP 的设置中 τ 是一个可学习的参数，其值接近 0.01。所以在下游任务中通常使用该值作为温度系数的固定值。本文在 $\tau \in \{0.001, 0.01, 0.1\}$ 范围内进行测试。如图 3-4 所示，当 $\tau = 0.01$ 时性能最佳；当 $\tau = 0.001$ 时，分布过于尖锐，较小的 τ 会造成训练的不稳定；当 $\tau = 0.1$ 时，分布过于平滑，削弱了模型对难样本的判别能力。




图 3-4 温度系数对模型分类性能的影响

Figure 3-4 The impact of temperature coefficient on model classification performance

3.3.6 案例分析

（1）多组案例的定量分析

本文筛选了三组内容相似的来自各类别的视频样本进行案例分析。其中一组包括十个拍摄内容为记录孩童生活的视频，第二组为七个内容为动物的视频，第三组为十个城市或自然景观的视频，具体的类别分布见表 3-8。

表 3-8 在 VideoEmotion-8 数据集上的案例分析
Table 3-8 Case analysis in VideoEmotion-8 dataset

组序	内容	样本量	样本分布
1	孩童	10	愤怒 2 愉悦 2 悲伤 2 期待 2 惊讶 2
2	动物	7	恐惧 2 厌恶 2 期待 2 信任 1
3	景观	10	愉悦 4 悲伤 3 期待 1 信任 2

在组 1 中，所提方法正确预测的样本数量为 5，作为对比，复现的 CTEN 在该组中正确预测的数量为 6，MM-VEMA 正确预测的数量为 4。DPFNet 和 MM-VEMA 作为整体预测准确率更高的方法，在该组案例中表现不佳的共同原因在于它们同为单视觉模态的方法，容易被相似内容的不同情感混淆。而在第二组和第三组中，DPFNet 分别正确预测了 5 和 8 个样例，MM-VEMA 正确预测了 5 和 7 个样例，而 CTEN 仅正确预测了 3 和 5 个样例，这反映了在 Kinetics 动作数据集上预训练的 CNN 模型的局限性，它使得模型无法解读出复杂多样的画面内容中集中体现情感线索的信息。

（2）案例可视化分析

为探究辅助文本如何影响模型分类，本文基于对视频帧的定位分析结合原视频画面的可视化来展示辅助文本对决策的影响。在 DPFNet 中，模型在解码器部分借助语义查询向量和交叉注意力关注视觉序列中重要的部分并抽取可用信息，而查询向量是最终决策的依据。所以，借助交叉注意力矩阵，可以分析得出序列中的哪些向量是被查询向量重点关注的。这些向量对应的注意力分数的反映了向量的受关注程度，所以将其命名为受关注分数。本文利用解码器最后一层的交叉注意力矩阵展开分析，因为其最接近决策层。同时，将多头注意力沿注意力头维度平均池化以得到多头平均注意力矩阵，获取更能够代表查询向量关注度的平均信息。由于双路解码器的设置，该注意力矩阵在主路径分支和辅助路径分支均会存在，分别反映主路径和辅助路径中哪些向量被查询向量关注。为方便表示，主路径中各向量的受关注分数统一记为 s_1 ，辅助路径则记为 s_2 。

图 3-5 展示了一个类别为“信任”的视频样本所包含的长度为 16 的向量序列对应的图像可视化和受关注分数。在此案例中，主路径最受关注的四个视觉序列向量序号分

别为 2、5、8、15，最不受关注的序号分别为 1、12、13、14；辅助路径最受关注的四个序号分别为 3、5、6、7，最不受关注的序号分别为 1、10、12、15。可以看出主路径更关注要素构成简单且情感倾向明确的图像，比如第 2 和第 8 张以“狗”为主体的画面。

“狗”在语义与“忠诚”、“伙伴”等词有潜在的关联，这可能是这些序列受关注的原因。辅助路径由辅助文本嵌入完全重构，所以不可能包含和“狗”一般具体的信息，但是其仍然关注到了第 3 和第 7 幅图像，这是辅助文本中“动物”一词对视觉输入重塑作用的体现。此外，辅助文本对视觉表达的约束作用在不受关注的向量上体现得更为明显。可以观察到，第 1 和第 10 幅图像都是较为空旷的背景，在此案例中无法提供有效信息；第 15 幅图像是与内容无关的字幕。这表明辅助文本降低了未被其定义的信息的关注度。主路径虽然同样降低了对空旷背景内容的关注，但是其忽视了类似于第 6、第 13 幅图像人与狗关系密切、同样能体现“信任”的画面。这些结论很好地揭示了主路径和辅助路径在决策过程中的倾向，同时验证了辅助文本对决策结果的正向影响。




图 3-5 视频样本可视化分析
Figure 3-5 Visual analysis of video sample

3.4 本章小结

本文提出一种基于跨模态交互的双路融合网络（DPFNet）。为了发挥视觉-语言模型在情感识别中的优势，模型设计了双通路编码结构，主通路通过自注意力机制建模视觉序列的时序依赖，辅助通路则引入情感辅助文本的语义知识来约束视觉特征表达。实验结果表明，双通路设计在一定程度上形成互补，有效提升了模型的准确性和鲁棒性。为克服视频中情感分布稀疏的问题，采用参数共享的双通路 Transformer 解码器，通过交叉注意力机制并行挖掘两路特征中的显著情感信息。最后，通过门控融合模块自适应聚合双路输出，有效抑制无关通道并突出关键情感内容。在两个公开数据集上的实验结果表明，所提模型有效提升了情感识别的准确率，同时降低了计算开销，提高了模型效率。在未来工作中，对于辅助文本的设计是值得深入探索的方向，以层次划分的辅助文本集或者结合检索增强技术可以提供更加合理的文本内容。此外后续研究将考虑使用蒸馏的方式在小模型上进一步提升模型效率，并拓展到在线视频情感识别的新研究领域。

第 4 章 基于渐进式原型演化的跨模态先验增强框架

本章针对用户视频场景下的视频情感识别问题，提出一种渐进式原型演化框架 PE-CLIP。该方法创新性地利用跨模态共享语义与模态特定归纳偏置作为先验知识，通过细粒度视觉-文本交互将中性原型逐步迁移为判别性情感表示，有效缓解了训练数据不足导致的过拟合问题。本章将详细阐述该框架的设计思路、技术实现及实验验证。

4.1 引言

由于训练数据有限且存在显著领域差异，从零开始训练深度网络面临巨大挑战，这将降低情感表征学习的最终效果。为缓解此类问题，先前方法主要依赖辅助数据^[30,31]或采取更复杂的训练策略^[25]。然而，现有研究尚未对其他模态的模型权重中的先验知识进行探索和利用。近期一项研究^[57]表明，即使是看似无关的模态，Transformer 模型仍可通过利用无关模态的互补知识提升模型在目标模态上的任务性能，且无需额外的无关模态数据输入。该方法通过两个结构相同的 Transformer（分别训练于不同模态）实现跨模态通用标记映射与交互规则的重用。然而，该方法受到架构限制，且未能充分利用无关模态的领域知识。受此启发，本文提出一种新方法，无需结构一致的同构模型，能够支持更灵活的模态领域先验知识迁移。




图 4-1 编码器范式（左）与原型演化范式（右）

Figure 4-1 Encoder paradigm (left) and prototype evolution paradigm (right)

为此，本文提出了一种新型解码器架构，建立了原型演化路径以逐步弥合情感鸿沟。如图 4-1 所示，与以往的编码器方法不同，所提方法采用经由预训练文本编码器改造的

多层解码器，通过引入 CLIP 文本编码器蕴含的丰富先验知识提升情感理解能力。解码器与中性的情感原型协同工作，引导原型向特定情感属性演化，动态生成与视觉内容对齐的情感表征。该架构通过大规模语义知识为原型演化路径提供语义支撑与逻辑解释，将情感鸿沟问题转化为目标域内更易处理的原型迁移问题，有效规避跨域迁移时的领域偏移不稳定的长久挑战。此外，该方法支持演化原型与预定义情感类别的语义锚点进行直接比对，从而实现鲁棒且可解释的分类。主要贡献包括：（1）提出 PE-CLIP 框架。该框架利用丰富的语言知识，将中性情感原型渐进演化为情感特异性表征；（2）设计类别聚合提示与双向监督机制，增强类别间关联性并稳定原型演化路径；（3）PE-CLIP 在参数效率方面表现优异，同时用户视频情感识别任务中达到新的 SOTA 性能。该方法还具备零样本迁移能力，无需任务特定微调即可对未见过的情感类别实现鲁棒泛化。

4.2 模型描述

所提出的 PE-CLIP 框架架构如图 4-2 所示。以下子章节将依次详细阐述各组成部分。




图 4-2 PE-CLIP 框架整体架构

Figure 4-2 Overall architecture of PE-CLIP framework

4.2.1 时空编码模块

参考近期在 UGVs 基准测试中迁移学习的实践^[41]，本文采用冻结的图像编码器以保留其丰富的语义先验知识。给定一个预处理后的输入视频 $V \in \mathbb{R}^{T \times 224 \times 224 \times 3}$ ，其中 T 表示

帧数，本文首先使用冻结的 CLIP 图像编码器提取帧级特征，取其类别标记[CLS]得到帧级特征 $\{z\}_{t=1}^T$ ，其中 $z_t \in \mathbb{R}^D$ ， D 表示嵌入维度。然后，这些帧级特征通过本文提出的多头 Mamba（MH-Mamba）架构进行时序相关性增强，产生细化后的特征 $\{z'_t\}_{t=1}^T$ ，其中 $z'_t \in \mathbb{R}^D$ 。

MH-Mamba 是专为时序依赖建模而改进的状态空间序列模型（SSM）^[58]的一个变体。与传统 SSM 通过单一隐藏状态转移处理序列不同，MH-Mamba 引入了具有 H 个头的并行扫描，其中每个头 $h \in \{1, \dots, H\}$ 维护独立的参数 $\{A^{(h)}, B^{(h)}, C^{(h)}\}$ ，这些参数由 $z_t^{(h)}$ 推导得到，用于离散化的状态空间方程：

$$x_t^{(h)} = \bar{A}^{(h)} x_{t-1}^{(h)} + \bar{B}^{(h)} z_t^{(h)} \quad (4-1)$$

$$y_t^{(h)} = C^{(h)} x_t^{(h)} \quad (4-2)$$

其中 $\bar{A}^{(h)}, \bar{B}^{(h)}$ 是通过零阶保持（ZOH）^[58]从连续对应参数 $A^{(h)}, B^{(h)}$ 推导出的离散化参数， $z_t^{(h)}$ 表示 z_t 的第 h 个头投影， $x_t^{(h)}$ 是隐式隐藏状态。多头输出 $\{y_t^{(h)}\}_{h=1}^H$ 被拼接并线性投影，形成细化后的时序嵌入 $z'_t \in \mathbb{R}^D$ ：

$$z'_t = \text{Concat}_{h=1}^H (y_t^{(h)}) W_o \quad (4-3)$$

其中 $y_t^{(h)} \in \mathbb{R}^{d_h}$ 是第 h 个头的输出， $W_o \in \mathbb{R}^{(Hd_h) \times D}$ 是一个可学习的投影矩阵。为简洁表达，在此公式中省略了辅助门控融合分支和残差连接的详细描述。MH-Mamba 设计实现了：（1）通过多头设置实现内存效率；（2）通过头特化捕获多样化的时序模式；（3）每个头的线性复杂度 $\mathcal{O}(T)$ 而 Transformer 为 $\mathcal{O}(T^2)$ 。

这些模块完成了视觉部分的时空编码任务，所以本文将它们一起归类为编码器。

4.2.2 基于 Transformer 的解码器

本文设计了一个利用可学习原型嵌入和随机初始化的 Transformer 解码器的解码器，该设置构成了该后续对比的基线模型。原型与视觉嵌入之间的交互通过多头交叉注意力机制完成。给定原型 $Q \in \mathbb{R}^{S \times D}$ （其中 S 是原型嵌入中标记的数量）和作为键与值的视觉嵌入 $Z \in \mathbb{R}^{T \times D}$ ，这种交互可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4-4)$$

$$\text{MultiHeadCrossAttention}(Q, Z) =$$

$$\text{Concat}_{h=1}^H \left(\text{Attention} \left(QW_q^{(h)}, ZW_k^{(h)}, ZW_v^{(h)} \right) \right) \quad (4-5)$$

其中, $W_q^{(h)}, W_k^{(h)}, W_v^{(h)} \in \mathbb{R}^{D \times d_k}$ 表示第 h 个注意力头的可训练投影, $d_k = D/H$, H 为注意力头数。多头输出被拼接并线性投影回原始嵌入维度。多头机制使模型能够同时关注不同的语义子空间, 增强了捕获多样情感线索的能力。此外, 解码器通过自注意力层进一步增强标记间的交互, 并通过前馈层以残差方式提升模型的表示能力。这样一个简单的模块可以达到与最先进方法^[41]相当的性能。然而, 将该模块扩展到更深层会导致性能下降, 可能是由于严重的过拟合。这一限制阻碍了模型在情感模式与视频语义之间建立更深层的关联。在实验中, 本文使用了 26 个可学习原型标记, 每个维度为 512。

4.2.3 原型衍生特征生成

所提基线模型通过编码器-解码器框架将视觉特征映射为情感表征。然而, 由于训练数据不足且情感鸿沟问题显著, 直接从零训练解码器并非良策。所以本文引入 CLIP 文本编码器初始化 PE-CLIP 解码器, 并冻结所有预训练参数。这一做法主要基于以下两点考量: (1) 对于长序列输入的视频任务, 采用全量微调计算效率低下; (2) 有限的训练数据易引发过拟合问题, 尤其在含大量可训练参数的网络中更为显著。大部分参数被冻结的情况下, 已有研究^[59]表明少量参数微调仍可适用于下游任务。所提解码器中可训练的交叉注意力层可作为适配器, 标记向量将被迫关注与文本关联性最高的视觉信息, 逐步将原型优化为最终的原型衍生特征。

实验表明, 并非需要在全部的 12 个解码层中应用交叉注意力机制。仅需修改顶部少数层为 PE-CLIP 解码层, 即可在降低可训练参数量的同时实现具有竞争力的性能。本文将起始解码器层 L_d 的 ID 记为 d , 修改层数记为 M 。所以 d 等于未修改层数, $M = 12 - d$ 。例如, 当从第零层开始修改 ($d = 0$) 时, 所有 Transformer 层都被修改为 PE-CLIP 解码器层。关于不同 d 值影响的详细讨论可在实验部分找到。注意, 本文保留了自注意力中的注意力掩码, 以确保 PE-CLIP 解码器与 CLIP 文本编码器在各层的任务相似性。所以只有[EOS]标记能够感知所有前面的标记。鉴于此, 本文始终使用 [EOS] 标记作为进一步计算的特征表示。

4.2.4 类别聚合提示生成

为了增强类别间的相关性和提示的语义丰富性, 本文提出了一种新颖的类别聚合提示 (Category aggregate prompt, CA prompt) 来生成分类器权重。在大多数传统分类任

务中^[29,31]，可训练的线性分类器是产生 logits 的最简单方法。分类器权重可以表述为一组向量 $\{w_i\}_{i=1}^n \in \mathbb{R}^D$ ，其中 n 是类别数。分类器权重和判别特征必须具有相同的维度以计算它们的内积。现有方法^[40]通过训练重新利用文本特征作为分类器权重，本文认为这种方法在视频空间中重新对齐了文本-视觉特征，所以不可避免地偏离了原始多模态特征空间。相反，本文直接采用文本特征作为分类器权重，因为原型衍生特征与 CLIP 的文本特征空间固有地相关。

此外，本文提出了一种构建类别聚合提示的新方法，通过负标签对比来加强类间相关性。给定所有情感类别 $emo_1, emo_2, \dots, emo_n$ 和一个选定的情感 emo_i ，本文构建相应的提示 p_i 为“without emo_1 ; ...; with emo_i ; ...; without emo_n ”。本文的提示方法类似于标记视频，其中相应类别使用“with”作为前缀，而其他类别使用“without”。通过拼接所有这些标签，获得提示 p_i ，并进一步通过 CLIP 文本编码器生成相应的分类器权重 w_i 。通常，本文利用经过最终文本投影的[EOS]标记作为分类器权重。此外，本文引入了一个特殊提示 p_0 ，其所有标签都使用“without”作为前缀，以替代可学习标记组成原型嵌入，通过 PE-CLIP 解码器产生原型衍生特征。这个中性提示在 CLIP 文本空间中提供了一个语义上有意义的参考点，表示没有任何情感属性。通过用 p_0 替换可学习嵌入，本文将原型锚定在一个人类可解释的概念上，增强了分类的可解释性和稳定性。logit 计算过程可表述如下：

$$w_i = \text{CLIP}_{\text{text}}(p_i), \quad (4-6)$$

其中， $\text{CLIP}_{\text{text}}(\cdot)$ 表示 CLIP 文本编码过程，使用投影后的[EOS]标记输出作为权重向量。同时， w_i 表示第 i 类的基于提示的分类器权重。

$$s_i = \frac{\exp(\cos(v_0, w_i)/\tau)}{\sum_{j=1}^n \exp(\cos(v_0, w_j)/\tau)}, \quad (4-7)$$

其中， s_i 表示样本属于类别 i 的最终概率， v_0 是原型衍生特征， τ 是温度参数。最后，本文定义任意两个向量 v 和 w 的余弦相似度函数 $\cos(v, w)$ 如下：

$$\cos(v, w) = \frac{\langle v, w \rangle}{\|v\|_2 \|w\|_2}, \quad (4-8)$$

其中， $\langle \cdot, \cdot \rangle$ 表示向量内积， $\|\cdot\|_2$ 表示 L2 范数。

4.2.5 双向监督

在本节中提出双向监督，一种联合优化前向监督和后向监督的新型训练策略，最大化基于提示的分类器权重 $\{w_i\}_{i=1}^n$ 与原型衍生特征 v_0 之间的相似度，使用交叉熵损失：

$$\mathcal{L}_{\text{forward}} = -\log \frac{\exp(\cos(v_0, w^+)/\tau)}{\sum_{i=1}^n \exp(\cos(v_0, w_i)/\tau)}, \quad (4-9)$$

其中 w^+ 是与真实类别对应的正向基于提示的分类器权重。后向监督与前向监督类似。给定一组提示 $\{p_i\}_{i=1}^n$ ，本文将它们作为不同类型的原型送入 PE-CLIP，并生成一组原型衍生特征 $\{v_i\}_{i=1}^n$ 。同时，本文使用真实提示 p^+ 获得特定的基于提示的分类器权重 w^+ 。形式上，后向监督损失可以计算为：

$$\mathcal{L}_{\text{backward}} = -\log \frac{\exp(\cos(v^+, w^+)/\tau)}{\sum_{i=1}^n \exp(\cos(v_i, w^+)/\tau)}. \quad (4-10)$$

总训练损失结合了两个监督分支：

$$\mathcal{L} = \lambda \mathcal{L}_{\text{forward}} + (1 - \lambda) \mathcal{L}_{\text{backward}}, \quad (4-11)$$

其中 λ 是平衡超参数。

4.3 实验结果与分析

4.3.1 数据集

与先前研究相同，本文在 VideoEmotion-8 数据集和 Ekman-6 数据集上评估所提方法。VideoEmotion-8 数据集包含从视频网站（YouTube 和 Flickr）采集的 1,101 个视频，标注有八种情感类别，平均时长 107 秒。为与现有工作公平比较，以开源数据集规定的划分方式进行十次 2:1 训练-测试划分的实验，取所有实验的平均准确率。类似地，Ekman-6 数据集包含 1,637 个来自 YouTube 和 Flickr 的视频，标注有六种基本情感，平均时长 112 秒。本文遵循先前研究使用的 1:1 训练-测试划分配置，并采用不同随机种子进行实验取平均准确率作为对比指标。此外，本文采用了 MusicVideo-6 数据^[60]，在该数据集上进行了三种不同的 2:1 训练-测试划分实验。MusicVideo-6 由在线来源的音乐视频组成，具有地理、语言、文化背景和乐器的显著多样性。公开版本包括 1979 个音乐视频片段，每个约 30 秒长。根据文献^[61-63]中定义的情感类别，这些视频传达的细粒度情感被分为六种基本类型：兴奋、恐惧、中性、放松、悲伤和紧张。

4.3.2 实现细节

对于所有数据集，本文首先使用 FFmpeg 以 30fps 提取帧。然后每个视频沿时间轴均匀划分为 64 个片段。在训练阶段，从每个片段随机采样一帧，而在评估阶段，本文采用每个片段内的中心帧采样以确保可重复性。对于空间归一化，帧被调整为 224×224 分辨率，同时通过中心裁剪保持宽高比。为减轻训练期间的过拟合，本文实施了一种轻

量级数据增强策略，包括随机调整大小裁剪，尺度参数在 $[0.64, 1]$ 内采样，纵横比限制在 $[3/4, 4/3]$ 内。值得注意的是，给定视频序列中的所有帧都应用相同的空间裁剪坐标以保持时间一致性。

PE-CLIP 使用 CLIP B/32 作为骨干网络提取帧级视觉特征。时序建模模块包含 3 个随机初始化的 Mamba 块。在 Transformer 和 Mamba 中均使用 512 的嵌入维度和 8 个头。具体而言，Mamba 中的内部维度、 Δ 的投影维度和状态维度分别设置为 384、16 和 4。平衡超参数 λ 设置为 0.7。此外，温度超参数 τ 设置为 0.01，起始解码器层 d 设置为 8。

优化方面，本文使用 Adam 优化器训练 50 个周期，批量大小为 16，学习率为 $2e-4$ 。所有实验均采用单标签情感分类，遵循情感识别的标准评估实践，性能通过 Top-1 准确率（%）量化。




图 4-3 实验所用数据集的样本在各类别中的分布

Figure 4-3 Category distributions in the experimental datasets

4.3.3 与最先进方法的对比

在表 4-1 中，本文将 PE-CLIP 与其他最先进方法在 VideoEmotion-8 和 Ekman-6 数据集上进行了比较。该框架在与先前 UGVs 基准测试相比时，优势尤为明显。PE-CLIP 在 VideoEmotion-8 和 Ekman-6 上分别达到了 64.5% 和 66.7% 的最新性能，显著优于先前的非 CLIP 先进方法如 MP_{EM}^[34]，分别高出 +6.9% 和 +5.4%。值得注意的是，基于 CLIP 的模型相比传统视觉骨干网络具有固有优势，即使是没有时序依赖建模的基本全微调方法（MM-VEMA）或简单基线也在每个数据集上超越了传统的视觉预训练方法。这表明视觉-语言预训练为情感识别任务提供了优越的基础表示。注意，大多数先前的视觉预训练方法采用多模态流水线来捕获模态互补特征，除了 IFPN 提出使用单模态特征。然而，它引入了一个辅助情感图像数据集来缩小领域差距。

在基于 CLIP 的方法中，该方法也显示出显著改进。尽管 TE^[41]在 UGVs 基准测试上取得了有竞争力的结果，但该架构在 VE-8 和 EK-6 上分别实现了+4.7%和+1.9%的提升，展示了 PE-CLIP 在 UGVs 情感理解中的卓越性能。

表 4-1 与最先进方法的比较（第一部分）

Table 4-1 Comparison with state-of-the-art methods (Part 1)

Method	Published	Modal	Auxiliary	VE-8	EK-6
ITE ^[19]	TAC'16	V+A	√	52.6	55.6
VAANet ^[29]	AAAI'20	V+A		54.5	55.3
TAM ^[30]	ACM MM'22	V+A	√	57.5	61.0
CTEN ^[25]	CVPR'23	V+A		57.3	58.2
IFPN ^[31]	TMM'23	V	√	57.6	60.4
LRCANet ^[33]	IET IP'24	V+A		57.4	59.8
MPEM ^[34]	Electronics'25	V+A		57.6	61.3
ST-Adapter ^[59]	NeurIPS'22	V		55.8	57.7
MM-VEMA ^[40]	PRCV'23	V		59.4	62.8
TE ^[41]	ACM MM'24	V+A		59.8	64.8
Baseline	Ours	V		61.1	62.4
PE-CLIP	Ours	V		64.5	66.7

表 4-2 与最先进方法的比较（第二部分）

Table 4-2 Comparison with state-of-the-art methods (Part 2)

Method	Published	Modal	#Frames	Top-1	Macro-F1
VAANet	AAAI'20	V+A	8×16	74.4	73.5
CTEN	CVPR'23	V+A	8×16	80.8	79.7
ST-Adapter	NeurIPS'22	V	16×1	80.2	79.6
MM-VEMA	PRCV'23	V	16×1	88.8	88.4
Baseline	Ours	V	64×1	88.3	87.9
PE-CLIP	Ours	V	16×1	89.9	89.4
PE-CLIP	Ours	V	64×1	91.5	90.9

此外，在 MusicVideo-6 数据集上进行了 SOTA 实验。实验结果见表 4-2。本文复现了最新发布的先进方法的代码。本文遵循先前论文中的最佳设置，仅调整片段数量以确保每种方法在训练期间充分利用内存。尽管 PE-CLIP 在节省训练内存方面具有优势，但仍在少量片段条件下进行实验以促进公平比较。再次发现基于 CLIP 的方法相比其他方法显示出显著改进。同时，基于 CLIP 的方法减少了对帧数的依赖，因为它们不需要连续帧来捕获 3D 视觉特征。相比之下，3D-CNN 方法受到大量输入帧的限制，难以在内存和性能之间找到平衡。它们还需要比基于 CLIP 的方法长 4 到 6 倍的训练时间。

图 4-4 中的混淆矩阵展示了 PE-CLIP 在六个情感类别上的分类性能。这些结果表明高唤醒度情感能被模型有效区分。然而，模型在中性类别的情感分类上准确率明显低于均值，其误分类分布在恐惧、悲伤和紧张中。这种情况表明中性状态可能与低唤醒度情感共享重叠特征。悲伤类别的识别准确率最低，有 7% 的样本被误分类为中性，4% 为恐惧，5% 为紧张。这表明悲伤情感表达表现出与其他低效价、低唤醒状态重叠的模糊特征。观察到的混淆模式与现有的情感心理学理论一致，其中在效价-唤醒空间中位置相似的情感具有更高的误分类率。悲伤和中性情感之间的主要混淆在理论上是一致的，因为两者都代表低唤醒状态，可能具有重叠特征。同时，高效价情感（兴奋）和低效价情感（悲伤、紧张）之间的非对角线值很小，表明在特征空间中具有清晰的分界线。




图 4-4 MusicVideo-6 实验的混淆矩阵

Figure 4-4 Confusion matrix for MusicVideo-6 experiment

4.3.4 消融实验与分析

为验证本文提出的网络中各组件的有效性，本文在 VideoEmotion-8 数据集上进行了系统的消融实验。所有实验均采用相同的训练策略和超参数设置，以确保比较的公平性。

(1) 关键组件有效性分析

在表 4-3 中报告了一些选定的消融研究。基于所提出的编码器-解码器框架评估了该主要扩展的有效性。组件消融研究从该基线开始，其中去除了时序建模模块和双向监督，采用可学习嵌入而非设计的提示嵌入。它仅维持了基本的编码器-解码器框架和基于提示的分类器权重，但未在 4 层解码器中使用预训练权重，这意味着除了冻结的 CLIP 图像编码器外，所有参数都需要训练。

表 4-3 在 VideoEmotion-8 和 MusicVideo-6 数据集上的组件消融研究
Table 4-3 Ablation study of components on VideoEmotion-8 and MusicVideo-6 datasets

Pretrained Decoder	Temporal Modeling	CA Prompt	Bidirectional Supervision	VE-8	MV-6
				61.1	88.3
✓				62.8	90.0
✓	✓			63.1	90.9
✓	✓		✓	63.9	90.9
✓	✓	✓		63.0	90.4
✓	✓	✓	✓	64.5	91.5

本文首先实验了该方法的核心组件消融。预训练解码器可以在每个数据集上提高+1.7%的准确率，这突出了文本先验对该方法的重要性。然后，本文引入了一个 3 层 Mamba 作为时序建模模块，分别将基线提升了+2.0%和+2.6%。这一结果表明 MH-Mamba 在提取视频片段中隐藏的时序依赖方面是有效的。有趣的是，原型类型和双向监督表现出复杂的相互作用。如表 4-3 的最后四行所示，在解码器中使用 CA 提示代替可学习嵌入会使 Top-1 准确率分别下降-0.1%和-0.5%。然而，当本文采用双向监督策略时，使用 CA 提示超过了可学习嵌入，在每个数据集上分别高出+0.6%。这一现象不仅反映了所提出的双向监督的有效性，也揭示了“查询工程”的潜力，类似于语言模型中“提示词工程”在提升模型表现方面的能力。本文将这部分留给未来探索。总体而言，在最优设置

下，PE-CLIP 可以将基线的 Top-1 准确率在两个数据集上分别从 61.1%和 88.3%提升至 64.5%和 91.5%。

（2）起始解码器层的影响

分析了不同起始解码器层 L_d 如何影响模型性能和内存效率。结果总结在图 4-5 中。如图所示，随着解码器层开始得越晚，训练参数线性减少。同时，模型性能在 $d = 8$ 时达到峰值。所以为了在性能和内存效率之间取得最佳权衡，仅使用少数顶层作为 PE-CLIP 解码器。值得注意的是，演化路径长度定义为 $12 - d$ 。当 d 从 11 减少到 8（对应增长的演化路径）时，观察到的持续性能改进为所提出的原型演化机制的有效性提供了定性证据。这一趋势表明，允许原型通过更多层演化可以实现更细粒度的迭代更新，进而增强模型捕获用户生成视频中细微情感线索的能力。




图 4-5 不同解码层起始位置下的模型性能和训练参数

Figure 4-5 Model performance and training parameters under different decoder starting positions

（3）不同分类器权重的实验

在 PE-CLIP 的一个变体上实施此实验，以确保架构一致性，因为在使用 PE-CLIP 时，不同的提示会在解码器中引入原型变量。具体而言，从 PE-CLIP 中剥离双向监督，并采用可学习嵌入而非 CA 提示来构建变体。这种设计将分类器权重生成策略的影响与其他组件隔离开来。实验中遵循实施细节中描述的配置。

本文将该类别聚合提示与三种代表性方法进行了比较：（1）可训练线性分类器：通过监督学习学习分类器权重的传统方法，其中每个权重向量随机初始化并通过反向传播优化；（2）基于情感提示的分类器^[40]：通过在类别特定的文本模板（例如，“this picture

evokes a feeling like {classname}”）上微调 CLIP 文本编码器，并使用得到的嵌入生成分类器权重；（3）基于 CoOp 提示的分类器^[64]：实现可学习的上下文向量，取代手工制作的提示。该方法在保持 CLIP 参数冻结的同时，通过梯度下降优化连续提示嵌入。

表 4-4 展示了所提出的类别聚合提示方法在所有数据集上的优越性。首先，可训练的线性分类器表现不如基于提示的方法，这表明在 CLIP 跨模态嵌入空间中，学习到的权重难以捕捉语义关系。其次，观察到 CoOp 的可学习提示相比情感提示虽有改进，但仍不及所提出的方法，这说明简单的类别名称替换缺乏足够的上下文建模能力，而我们提出的显式“with/without”的正负语义对比机制则能提供更具有区分性的上下文。相较于 CoOp 方法 0.3%至 0.6%的性能提升，凸显了通过负标记对比进行显式类别关系建模的有效性。

表 4-4 不同分类器权重的比较
Table 4-4 Comparison of different classifier weights

Method	VideoEmotion-8	Ekman-6
Trainable Linear	59.8	62.7
Emotional	61.2	63.9
CoOp	62.5	65.0
CA (Ours)	63.1	65.3

（4）时序建模方法的实验

本文将各种时序建模方法与所提出的 MH-Mamba 在 VideoEmotion-8 和 MusicVideo-6 数据集上进行了比较，如表 4-5 所示。结果证明了该方法在不同基准测试上的一致优势。

该评估从使用 3 层 Transformer 和 3 层 Mamba 模块进行时序建模开始。Transformer 在 VideoEmotion-8 上达到 61.5%，在 MusicVideo-6 上达到 88.2%，比无时序的 Identity 设置分别低-1.3%和-1.8%。相比之下，Mamba 超过基线+0.3%和+0.9%，达到 63.1%和 90.9%。这表明 Transformer 可能遭受过拟合，而 Mamba 在捕获时序依赖方面更为有效。

进一步考察了传统的循环架构，包括 LSTM 和 GRU 两种方法，表现均不如 Mamba。LSTM 在 VideoEmotion-8 上达到 60.6%，GRU 达到 60.1%。这种性能差距也体现在 MusicVideo-6 上，MH-Mamba 以 90.9%的最高准确率优于 LSTM 的 88.1%和 GRU 的 86.5%。这些数据验证了 MH-Mamba 在时序情感理解中的有效性。

表 4-5 不同时序建模模块的比较
Table 4-5 Comparison of different temporal modeling modules

Method	VideoEmotion-8	MusicVideo-6
Identity	62.8	90.0
LSTM	60.6	88.1
GRU	60.1	86.5
Transformer	61.5	88.2
MH-Mamba	63.1	90.9

(5) 片段数量实验

本文研究了不同片段数量对模型性能的影响，全面结果见表 4-6。分析显示，在 VideoEmotion-8 和 MusicVideo-6 两个数据集上存在一致趋势，性能随片段数量增加先提升后下降。

实验表明，64 个片段在两个基准测试上均达到最优性能，在 VideoEmotion-8 上为 64.5%，在 MusicVideo-6 上为 91.5%。当使用较少片段时，模型捕获的时序信息不足，导致在 16 个片段时分别在相应数据集上性能降低，为 61.3%和 89.9%。值得注意的是，扩展到 128 个片段会导致性能下降，在 VideoEmotion-8 上准确率降至 63.1%，在 MusicVideo-6 上降至 90.8%。这一现象表明，过度的片段化可能会引入冗余信息或噪声，阻碍有效的时序建模。

表 4-6 不同片段数量的比较
Table 4-6 Comparison of different numbers of segments

Dataset	Number of Frames			
	16	32	64	128
VideoEmotion-8	61.3	62.6	64.5	63.1
MusicVideo-6	89.9	90.3	91.5	90.8

4.3.5 提示敏感性分析

为了检验 CA 提示是否对语言变化具有鲁棒性，且不依赖于表面的提示伪影，在 MusicVideo-6 数据集上进行了一系列控制实验。所有结果均通过每视频采样 16 帧获得，并在三个数据划分上取平均。这些实验表明，模型性能在各种提示变化下保持合理稳定。如表 4-7 所示，不同提示修改引起的性能变化通常很小；当三种修改组合时，最大下降

为 0.6%，而改变分隔符甚至略微提高了准确率。所有变体均保持有竞争力的性能。所以得出结论，所提出的提示设计不存在严重的提示伪影问题。

表 4-7 提示词变体实验
Table 4-7 Experiments on prompt variants

Prefix Word	Separator	Category Order	Top-1Acc
			89.9
✓			89.6
	✓		91.0
		✓	89.4
✓	✓	✓	89.3

(1) 前缀词

本文将前缀词“without”替换为“no”，将“with”替换为“only”。原始包含“with”和“without”的提示取得了最高性能，而替代措辞导致轻微下降。相对较小的性能差距表明模型对确切措辞不过于敏感。

(2) 分隔符

改变了用于连接提示内类别标签的分隔符：(a) 分号+空格（原始设置），和 (b) 逗号+空格。分隔符的影响可忽略不计，表明解码器主要依赖语义内容而非具体标点。

(3) 类别顺序

在保持前缀和分隔符不变的情况下，反转了所有情感标签的顺序。准确率下降了 0.5%，略大于前缀词变化引起的波动，但仍在小范围内。这表明 CA 提示在不同顺序下也能有效运作。

(4) 原型标记数量

此外，本文研究了原型标记数量对 VideoEmotion-8 数据集上模型性能的影响。在此实验中，本文每视频采样 64 帧，移除双向监督，并采用可学习原型，这为研究原型标记数量的影响提供了合适的环境。如表 4-8 所示，本文评估了不同长度的原型：2、14、26、38 和 50 个标记。结果表明，仅使用 2 个标记会显著降低性能，而增加到 14 个标记取得最佳结果。进一步增加标记数量至 26、38 或 50 导致轻微性能下降，但保持在 63.1% 准确率附近稳定。这表明只要提供足够的长度，模型对原型标记的确切数量并不高度敏感。

表 4-8 不同原型标记数量的比较

Table 4-8 Comparison of different numbers of prototype tokens

Metric	Numbers of Prototype Tokens				
	2	14	26	38	50
Top-1Acc	62.0	63.4	63.1	62.9	63.1
Macro-F1	59.1	60.3	60.0	59.8	60.1

4.3.6 可视化分析

图 4-6 比较了 PE-CLIP 与基线模型的特征表示的 t-SNE 可视化。PE-CLIP 在情感特征空间中展现出显著更紧密和更清晰的聚类形成。通过轮廓系数定量验证：PE-CLIP 为 0.093，而基线模型为 0.045。这一改进证实了 PE-CLIP 的原型演化设计带来的优越判别能力，更好地保持了情感类别间的内在情感结构和可分性。




图 4-6 PE-CLIP 与基线模型输出嵌入的 t-SNE 可视化

Figure 4-6 t-SNE visualization of output embeddings for PE-CLIP and baseline model

4.3.7 内存效率

尽管更简单的仅编码器方法^[29]可以与 PE-CLIP 的计算效率相较，但它们在性能上表现较为弱势。在具有竞争力的方法中，PE-CLIP 显示出较低的计算需求。TE^[41]在性能上排名第二，它引入 CLIP 的视觉特征作为第三种模态。其多层跨模态时序增强模块旨在增强模态间相关性，需要比其他任何方法都多得多的计算资源。相比之下，本文方法在实现最先进性能的同时保持了卓越的参数效率，在计算需求和模型有效性之间建立了最佳平衡。

尽管需要更多计算成本，PE-CLIP 仍保持其内存效率优势。如表 4-9 所示，MM-VEMA 和 ST-Adapter^[59]在处理相同数量的输入帧时需要大约 2.7 倍的内存容量。即使 PE-CLIP 处理更长的序列，这一效率优势依然存在。相比之下，PE-CLIP 采用了类似于 ST-Adapter 的参数高效架构，保留了预训练骨干网络，仅训练部分模块，增加了极少的额外参数。这种参数效率与操作有效性的结合使得该方法成为实际视频理解应用的理想选择。

表 4-9 模型效率比较（参数与内存使用）

Table 4-9 Model efficiency comparison (parameters and memory usage)

Method	TrainableParameters	Frames	MemoryUsage(GB)	GFLOPs
VAANet	48.2	8×16	6.9	120
CTEN	202.9	8×16	12.5	360
MM-VEMA	577.1	16×1	16.4	87
ST-Adapter	27.1	16×1	16.7	72
PE-CLIP(Ours)	31.3	16×1	6.0	108
PE-CLIP(Ours)	31.3	64×1	9.3	317

4.4 本章小结

在本文中，本文提出了 PE-CLIP，一个用于 UGVs 情感识别的参数高效框架，通过原型演化有效弥合了情感鸿沟。通过充分利用 CLIP 的视觉-语言对齐和文本先验，该方法在 UGVs 基准测试上实现了最先进的性能，同时保持了计算效率。所提出的原型演化路径和带有双向监督的类别聚合提示实现了稳健的情感建模，克服了传统仅编码器范式的局限性。大量实验证明了相比现有方法的显著改进。除了视频情感识别，所提出的原型演化范式有望应用于更广泛的视觉-语言任务，这些任务的特点是需要细粒度的语义理解和跨模态对齐。未来工作可以探索将该框架扩展到其他基础模型（如 BLIP）以及涉及更复杂多模态交互的任务，如视频问答或多模态检索。

第5章 结论与展望

本文围绕复杂拍摄场景中的视频情感识别问题展开了深入研究，针对用户视频场景中视觉内容多样、情感分布稀疏、标注数据稀缺等核心挑战，提出了两种创新性的解决方案。本文的主要研究工作与贡献总结如下：

第一，针对复杂场景中视频情感识别面临的独特挑战，本文提出了一种基于注意力机制的双通路融合网络 DPFNet。该方法创新性地设计了双通路编码结构，主通路通过自注意力机制捕捉视觉序列的时序依赖，辅助通路则引入情感辅助文本约束视觉特征表达。通过参数共享的双通路 Transformer 解码器和动态门控融合机制，模型能够自适应地关注稀疏的情感线索并抑制无关噪声。实验结果表明，DPFNet 在仅依赖视觉模态输入的情况下，在 VideoEmotion-8 和 Ekman-6 数据集上分别取得了 60.2%和 63.7%的准确率，实现了性能与效率的良好平衡。

第二，针对标注稀缺导致的过拟合问题，本文提出了一种基于渐进式原型演化的跨模态先验增强框架 PE-CLIP。该方法充分利用 CLIP 预训练模型中的语言知识先验，通过原型演化路径将中性情感原型渐进转化为判别性情感表征。设计的类别聚合提示与双向监督机制有效增强了类别间关联性并稳定了原型演化过程。在 VideoEmotion-8、Ekman-6 和 MusicVideo-6 等多个数据集上的实验表明，PE-CLIP 取得了领先的性能，验证了利用辅助模态先验增强单模态情感建模的有效性。

尽管本文在视频情感识别领域取得了一定的进展，但仍存在以下值得进一步探索的研究方向。首先，在动态场景适应方面，当前方法主要针对离线视频分析，未来可探索在线视频情感识别场景，实现对视频流的实时情感分析。这需要进一步优化模型的推理效率，并设计增量学习机制以适应不断变化的数据分布。其次，在跨域泛化能力方面，现有模型在特定数据集上表现良好，但在不同领域、不同文化背景的视频数据上的泛化能力仍有待提升。未来研究可探索域自适应技术或元学习方法，提升模型的跨域迁移能力。再者，在轻量化部署方面，尽管本文方法在参数效率上已有所优化，但在边缘设备上的部署仍面临挑战。后续研究可结合知识蒸馏、模型量化等技术，进一步压缩模型体积，满足实际应用中的部署需求。最后，在多模态协同方面，本文方法虽然降低了对多模态数据的依赖，但在音频、文本等辅助模态可用时，如何更好地融合多模态信息以进一步提升识别性能，仍是一个值得深入研究的方向。

综上所述,本文提出的两种方法从不同角度解决了复杂场景视频情感识别中的关键问题,为后续研究提供了新的思路和技术基础。随着视觉-语言模型的不断发展,视频情感识别技术有望在智能推荐、人机交互、情感计算等领域发挥更加重要的作用。

参考文献

- [1] 陶建华, 范存航, 连政, 等. 多模态情感识别与理解发展现状及趋势[J]. 中国图象图形学报, 2024, 29(06): 1607-1627.
- [2] Zadeh A, Zellers R, Pincus E, et al. Multimodal sentiment intensity analysis in videos: facial gestures and verbal messages[J]. IEEE Intelligent Systems, 2016, 31 (6): 82-88.
- [3] Busso C, Bulut M, Lee C C, et al. IEMOCAP: interactive emotional dyadic motion capture database[J]. Language Resources and Evaluation, 2008, 42(4): 335-359.
- [4] Zadeh A, Chen M, Poria S, et al. Tensor fusion network for multimodal sentiment analysis[C] //Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 1103-1114.
- [5] Rahman W, Hasan M K, Lee S, et al. Integrating multimodal information in large pretrained transformers[C] //Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 2359-2369.
- [6] Mai SJ, Zeng Y, Zheng SJ, et al. Hybrid contrastive learning of tri-modal representation for multimodal sentiment analysis[J]. IEEE Transactions on Affective Computing, 2022, 14(3): 2276-2289.
- [7] 缪裕青, 杨爽, 刘同来, 等. 基于跨模态门控机制和改进融合方法的多模态情感分析[J]. 计算机应用研究, 2023, 40 (07): 2025-2030+2038.
- [8] 冯广, 刘馨婷, 林忆宝, 等. 基于统一对齐与多阶段融合机制的多模态情感分析模型[J]. 计算机应用研究, 1-12. <https://doi.org/10.19734/j.issn.1001-3695.2025.06.0214>.
- [9] Grosu M, Mirela M, Octaviana D, et al. A comparative study of emotion recognition systems: From classical approaches to multimodal large language models[J]. Applied Sciences, 2026, 16(3): 1289. <https://doi.org/10.3390/app16031289>.
- [10] Xu LW, Wang ZT, Wu B, et al. MDAN: multi-level dependent attention network for visual emotion analysis[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2022: 9479-9488.
- [11] Sebe N, Cohen I, Gevers T, et al. Multimodal approaches for emotion recognition: a survey[C] //Internet Imaging VI. SPIE, 2005, 5670: 56-67.

- [12]De S, Liyanage C, Miyasato T, et al. Facial emotion recognition using multi-modal information[C] //Proceedings of ICICS, 1997 International Conference on Information, Communications and Signal Processing. Piscataway, NJ: IEEE Press, 1997, 1: 397-401.
- [13]Chen L S, Huang T S. Emotional expressions in audiovisual human computer interaction[C] //Proceedings of 2000 IEEE International Conference on Multimedia and Expo 2000. 2000, 1: 423-426.
- [14]Yoshitomi Y, Kim S I, Kawano T, et al. Effect of sensor fusion for recognition of emotional states using voice, face image and thermal image of face[C] //Proceedings of the 9th IEEE International Workshop on Robot and Human Interactive Communication. Piscataway, NJ: IEEE Press, 2000: 178-183.
- [15]Piana S, Stagliano A, Odone F, et al. Real-time automatic emotion recognition from body gestures[J/OL]. arXiv preprint arXiv:1402.5047, 2014.
- [16]Castellano G, Kessous L, Caridakis G. Emotion recognition through multiple modalities: face, body gesture, speech[M]. Affect and Emotion in Human-Computer Interaction: From Theory to Applications, 2008: 92-103.
- [17]刘婷婷, 刘箴, 柴艳杰, 等. 人机交互中的智能体情感计算研究[J]. 中国图象图形学报, 2021, 026(012):2767-2777.
- [18]You QZ, Luo J, Jin HL, et al. Robust image sentiment analysis using progressively trained and domain transferred deep networks[C] //Proceedings of the AAAI conference on Artificial Intelligence. 2015, 29(1).
- [19]Xu BH, Fu YW, Jiang YG, et al. Heterogeneous knowledge transfer in video emotion recognition, attribution and summarization[J]. IEEE Transactions on Affective Computing, 2016, 9(2): 255-270.
- [20]Wöllmer M, Weninger F, Knaup T, et al. Youtube movie reviews: Sentiment analysis in an audio-visual context[J]. IEEE Intelligent Systems, 2013, 28(3): 46-53.
- [21]Poria S, Chaturvedi I, Cambria E, et al. Convolutional MKL based multimodal emotion recognition and sentiment analysis[C] //2016 IEEE 16th international conference on data mining (ICDM). IEEE, 2016: 439-448.
- [22]Tran D, Bourdev L, Fergus R, et al. Learning spatiotemporal features with 3d

- p>convolutional networks[C] //Proceedings of the IEEE international conference on computer vision. 2015: 4489-4497.
- [23]Fan Y, Lu XJ, Li D, et al. Video-based emotion recognition using CNN-RNN and C3D hybrid networks[C] //Proceedings of the 18th ACM international conference on multimodal interaction. 2016: 445-450.
- [24]Mai SJ, Hu HF, Xu J, et al. Multi-fusion residual memory network for multimodal human sentiment comprehension[J]. IEEE Transactions on Affective Computing, 2020, 13(1): 320-334.
- [25]Zhang ZC, Wang LJ, Yang JF. Weakly supervised video emotion detection and prediction via cross-modal temporal erasing network[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 18888-18897.
- [26]Li F, Wu K, Li YW. MCN-CL: Multimodal cross-attention network and contrastive learning for multimodal emotion recognition[C] //International Conference on Multimedia Modeling. Singapore: Springer Nature Singapore, 2026: 561-574.
- [27]Zadeh A, Liang P P, Poria S, et al. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph[C] //Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL). 2018: 2236-2246.
- [28]Poria S, Hazarika D, Majumder N, et al. MELD: A multimodal multi-party dataset for emotion recognition in conversations[C] //Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL). 2019: 527-536.
- [29]Zhao SC, Ma YS, Gu Y, et al. An end-to-end visual-audio attention network for emotion recognition in user-generated videos[C] //Proceedings of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2020, 34(01): 303-311.
- [30]Pan JC, Wang SF, Fang L. Representation learning through multimodal attention and time-sync comments for affective video content analysis[C] //Proceedings of the 30th ACM International Conference on Multimedia. New York: ACM Press, 2022: 42-50.
- [31]Zhang HM, Xu M. Recognition of emotions in user-generated videos through frame-level adaptation and emotion intensity learning[J]. IEEE Transactions on Multimedia, 2023,

- 25: 881-891.
- [32] You QZ, Luo JB, Jin HL, et al. Building a large scale dataset for image emotion recognition: the fine print and the benchmark[C] //Proceedings of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2016, 30(1).
- [33] Yi Y, Zhou J, Wang HL, et al. Emotion recognition in user-generated videos with long-range correlation-aware network[J]. IET Image Processing, 2024, 18(12): 3288-3301.
- [34] Zhang LQ, Sun Y, Guan JS, et al. Multi-scale parallel enhancement module with cross-hierarchy interaction for video emotion recognition[J]. Electronics, 2025, 14(9): 1886.
- [35] Deng J, Dong W, Socher R, et al. Imagenet: a large-scale hierarchical image database[C] //2009 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2009: 248-255.
- [36] Carreira J, Zisserman A. Quo vadis, action recognition? a new model and the kinetics dataset[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2017: 6299-6308.
- [37] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C] //International Conference on Machine Learning. 2021: 8748-8763.
- [38] Kahatapitiya K, Arnab A, Nagrani A, et al. Victr: video-conditioned text representations for activity recognition[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2024: 18547-18558.
- [39] Yu YT, Cao CQ, Zhang YR, et al. Building a multi-modal spatiotemporal expert for zero-shot action recognition with clip[C] //Proceedings of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2025, 39(9): 9689-9697.
- [40] Pu H, Sun YC, Song RH, et al. Going beyond closed sets: a multimodal perspective for video emotion analysis[C] //Chinese Conference on Pattern Recognition and Computer Vision. Singapore: Springer Nature Singapore, 2023: 233-244.
- [41] Li Xin, Wang Shangfei, Huang Xuandong. Temporal enhancement for video affective

- content analysis[C] //Proceedings of the 32nd ACM International Conference on Multimedia. New York: ACM Press, 2024: 642-650.
- [42]Hu GY, Kollias D, Yang XY. Grounding emotion recognition with visual prototypes: VEGA-Revisiting CLIP in MERC[C] //Proceedings of the 33rd ACM International Conference on Multimedia. 2025: 5667-5676.
- [43]Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [44]Wu SX, Dai DM, Qin ZW, et al. Denoising bottleneck with mutual information maximization for video multimodal fusion[C] //Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 2231-2243.
- [45]He KM, Zhang XY, Ren SQ, et al. Deep residual learning for image recognition[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778.
- [46]Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale[C] //International Conference on Learning Representations (ICLR). 2021.
- [47]Luhn H P. A statistical approach to mechanized encoding and searching of literary information[J]. IBM Journal of Research and Development, 1957, 1(4): 309-317.
- [48]Sparck Jones K. A statistical interpretation of term specificity and its application in retrieval[J]. Journal of Documentation, 1972, 28(1): 11-21.
- [49]Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J/OL]. arXiv preprint arXiv:1301.3781, 2013.
- [50]Pennington J, Socher R, Manning C D. GloVe: Global vectors for word representation[C] //Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014: 1532-1543.
- [51]Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations[C] //Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT). 2018:

- 2227-2237.
- [52]Radford A, Narasimhan K, Salimans T, et al. Improving language understanding by generative pre-training[J/OL]. OpenAI, 2018.
- [53]Baevski A, Zhou Y, Mohamed A, et al. wav2vec 2.0: A framework for self-supervised learning of speech representations[C] //Advances in Neural Information Processing Systems. 2020, 33: 12449-12460.
- [54]Hallur S, Gavade A, Gavade P. A survey on video emotion recognition: Segmentation, classification, and explainable AI techniques[J]. Signal Processing: Image Communication, 2025: 117442.
- [55]Jiang YG, Xu BH, Xue XY. Predicting emotions in user-generated videos[C] //Proceedings of the AAAI Conference on Artificial Intelligence. CA: AAAI Press, 2014, 28(1).
- [56]Song YH, Cho SY. Leveraging CLIP encoder for multimodal emotion recognition[C] //2025 IEEE/CVF Winter Conference on Applications of Computer Vision. IEEE, 2025: 6115-6124.
- [57]Zhang YY, Ding XH, Gong KX, et al. Multimodal pathway: Improve transformers with irrelevant data from other modalities[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 6108-6117.
- [58]Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[C] //First conference on language modeling. 2024.
- [59]Pan JT, Lin ZY, Zhu XT, et al. St-adapter: Parameter-efficient image-to-video transfer learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 26462-26477.
- [60]Pandeya Y R, Lee J. Deep learning-based late fusion of multimodal information for emotion classification of music video[J]. Multimedia Tools and Applications, 2021, 80(2): 2887-2905.
- [61]Sun K, Yu JQ, Huang Y, et al. An improved valence-arousal emotion space for video affective content representation and recognition[C] //2009 IEEE International Conference on Multimedia and Expo. 2009: 566-569.

- [62]Ouyang X, Kawaai S, Goh E G H, et al. Audio-visual emotion recognition using deep transfer learning and multiple temporal models[C] //Proceedings of the 19th ACM international conference on multimodal interaction. 2017: 577-582.
- [63] Zhang LG, Zhang JL. Synchronous prediction of arousal and valence using LSTM network for affective video content analysis[C] //2017 13th international conference on natural computation, fuzzy systems and knowledge discovery (ICNC-FSKD). 2017: 727-732.
- [64]Zhou KY, Yang JK, Loy C C, et al. Learning to prompt for vision-language models[J]. International Journal of Computer Vision, 2022, 130(9): 2337-2348.

攻读硕士学位期间取得的研究成果

（1）攻读硕士学位期间申请的发明专利

- [1] 刘玉杰, 王一雯, **董振阳**, 等. 一种基于多模态特征融合与微调的微姿态识别方法: CN120220244A[P]. 2025-06-27.

（2）攻读硕士学位期间发表的学术论文

- [1] Yujie Liu, **Zhenyang Dong**, Yante Li, et al. Building prototype evolution pathway for emotion recognition in user-generated videos[J]. Big Data Cogn. Comput. 2026, 10, 73. <https://doi.org/10.3390/bdcc10030073>.
- [2] 刘玉杰, **董振阳**. 基于双通路融合网络的用户视频情感识别[J]. 计算机应用研究, 2026, 已录用待发表.

致 谢

岁月如梭，三载研究生涯转瞬即逝，回首来时路，心中充满感恩与感慨。论文的顺利完成，离不开众多师长、同学和家人的支持与帮助，在此谨向他们致以最诚挚的谢意。

首先，衷心感谢我的导师刘玉杰副教授。从研究课题的选定、方案的设计，到论文的撰写与修改，导师始终给予我悉心的指导与耐心的帮助。导师严谨的治学态度、深厚的学术功底以及对科研工作的热忱，令我深受感染，使我受益终身。能够在导师的指导下完成这段求学历程，是我莫大的荣幸。

其次，感谢中国石油大学（华东）计算机科学与技术学院的各位老师，在研究生阶段为我传授了扎实的理论知识，拓宽了我的学术视野。感谢课题组的各位同学，三年来大家共同学习、相互切磋，在思想碰撞中为我提供了诸多宝贵的启发与帮助，课题组的温暖氛围将是我珍藏一生的美好记忆。

此外，感谢 VideoEmotion-8、Ekman-6 等公开数据集的研究者们，为视频情感识别领域的发展做出了重要贡献，也为本研究提供了可靠的实验基础。

最后，将最深沉的感谢献给我的家人。感谢父母多年来的养育之恩与无私支持，正是他们的理解与鼓励，成为我在学术道路上不断前行的最大动力。

本文的研究工作尚存在诸多不足，恳请各位专家、学者批评指正。谨以此文献给所有关心和支持我的人。